



**UNIVERSIDAD DE ORIENTE
NÚCLEO DE MONAGAS
ESCUELA DE INGENIERÍA Y CIENCIAS APLICADAS
DEPARTAMENTO DE INGENIERÍA DE SISTEMAS
GERENCIA DE SISTEMAS DE PRODUCCIÓN**

**SISTEMA PREDICTIVO BASADO EN MACHINE LEARNING PARA
LA OPTIMIZACIÓN DE INVENTARIOS PERECEDEROS DE LA
INDUSTRIA REPOSTERA EN LA PASTELERÍA CASSERÍSSIMAS,
MATURÍN, ESTADO MONAGAS.**

Monografía de Investigación, en Modalidad Cursos Especiales de
Grado, presentado como requisito parcial para optar al título de Ingeniero de
Sistemas

Autores:

Br. Jorfran Gil

C.I: 26.933.738

Br. Yefferson Hernández

C.I: 29.936.033

Tutor Académico:

Juan Oliveira

Maturín, agosto del 2026

ÍNDICE GENERAL

CAPÍTULO I.....	4
EL PROBLEMA Y SUS GENERALIDADES	4
1.1 Planteamiento del Problema	4
1.2 OBJETIVOS DE LA INVESTIGACIÓN.....	7
1.2.1 Objetivo General.....	7
1.2.2 Objetivos Específicos.....	7
1.3 JUSTIFICACIÓN DE LA INVESTIGACIÓN	9
1.4 DELIMITACIÓN DE LA INVESTIGACIÓN.....	11
CAPÍTULO II.....	13
MARCO TEORICO	13
2.1 Antecedentes de la investigación	13
2.2 Ubicación y Descripción del Área en Estudio	15
2.2.2 Reseña histórica de la empresa	16
2.2.3 Misión	16
2.2.4 Visión	17
2.2.5 Estructura organizativa.....	17
2.3 BASES TEÓRICAS.....	18
2.3.1 Sistemas predictivos.....	19
2.3.2 Machine learning (aprendizaje automático)	22
2.3.3 Optimización de inventarios perecederos	28
2.3.4 Industria repostería	35
2.4 BASES LEGALES.....	37
2.4.1 Constitución de la República Bolivariana de Venezuela (1999)	37
2.4.2 Ley Orgánica del Sistema Venezolano para la Calidad (2002)	38
2.4.3 Ley Orgánica de Seguridad y Soberanía Agroalimentaria (2008)	39
2.4.4 Ley Especial Contra los Delitos Informáticos (2001)	39
2.5 DEFINICIÓN DE TÉRMINOS BÁSICOS.....	40
CAPÍTULO III.....	42
MARCO METODOLÓGICO.....	42

3.1 TIPO DE INVESTIGACIÓN	42
3.2 NIVEL DE LA INVESTIGACIÓN.....	43
3.3 DISEÑO DE LA INVESTIGACIÓN	44
3.4 POBLACIÓN Y MUESTRA	45
3.4.1 Población.....	45
3.4.2 Muestra	46
3.5 TÉCNICAS E INSTRUMENTOS DE RECOLECCIÓN DE DATOS	47
3.5.1 Observación Directa	47
3.5.2 Entrevista Semiestructurada	48
3.5.3 Revisión Documental	49
3.6 TÉCNICAS E INSTRUMENTOS DE ANÁLISIS DE DATOS	49
3.6.1 Análisis Exploratorio de Datos (EDA)	50
3.6.2 Ingeniería de Características (Feature Engineering).....	51
3.6.3 Entrenamiento y Validación del Modelo Random Forest	51
3.6.4 Evaluación Mediante Métricas Estadísticas: MAPE y RMSE	52
3.6.5 Validación Retrospectiva mediante Backtesting (Walk-Forward Validation)	53
3.7 DISEÑO OPERATIVO.....	54
3.7.1 Fase I: Diagnóstico.....	57
3.7.2 Fase II: Modelado.....	58
3.7.3 Fase III: Desarrollo.....	58
3.7.4 Fase IV: Validación	59
Referencias.....	60

CAPÍTULO I

EL PROBLEMA Y SUS GENERALIDADES

1.1 Planteamiento del Problema

En el contexto global contemporáneo, la industria alimentaria y, específicamente, el sector repostero la gestión eficiente de inventarios en la industria alimentaria constituye un pilar estratégico para favorecer la viabilidad operativa, más cuando se manejan productos con poca vida útil como esto supone un reto logístico la cadena de suministro repostera exige una sincronización precisa entre la oferta y la demanda para mantener la rentabilidad y la continuidad de las operaciones. De hecho, La Organización de las Naciones Unidas para la Alimentación y la Agricultura (FAO, 2023) alerta sobre pérdidas del 14 por ciento de alimentos perecederos a escala global durante las etapas antes de la venta comercial debido a las debilidades en la cadena logística.

Esta exigencia logística se agudiza drásticamente en el entorno económico venezolano, Tradicionalmente, las empresas del sector emplean métodos heurísticos o solo se centran en su experiencia para llevar a cabo sus requerimientos diarios. Sin embargo, estas prácticas son ineficientes para poder adaptarse a lo que pasa día a día en el mercado actual. Debido a esto, los responsables de almacén generan compras inexactas y excesos de producción que culminan en desperdicios significativos.

Tal como documenta el Consejo Nacional del Comercio y los Servicios (Consecomercio, 2023), la economía que vivimos en la actualidad sufre de una alta volatilidad del mercado y fluctuaciones constantes en la disponibilidad de

materias primas. Las continuas distorsiones en la cadena de suministro nacional impulsan a las empresas a transicionar hacia herramientas de gestión tecnológica para mitigar la descapitalización por mermas.

Esta necesidad de optimización operativa se evidencia directamente en la Pastelería Casserissima C.A., una organización del sector repostero ubicada en Maturín, estado Monagas. Actualmente, la empresa maneja un catálogo operativo de aproximadamente 80 unidades de mantenimiento de stock (SKU) críticos, Incluye insumos con alta rotación y caducidad acelerada como leches, huevos, frutas frescas y harinas especializadas. El flujo de materiales y la vigilancia de estos inventarios son administrados mediante métodos empíricos y hojas de cálculo sin integrales, lo cual produce una visibilidad insuficiente del comportamiento de la estacionalidad en entornos aleatorios.

Por tanto, en la vida diaria la implementación de este enfoque conlleva un procedimiento ineficaz donde el responsable operativo tiene que llevar a cabo contabilizaciones visuales diarias que posteriormente se comparan con facturas físicas de los proveedores. Tal deficiencia metodológica provoca que las tomas de decisión se prolonguen significativamente y se evite la implantación de estrategias prioritarias, como la clasificación ABC, convirtiendo a insumos cruciales de caducidad rápida y a materiales menos importantes financieramente en tratamientos igualitarios empíricos.

Esta deficiencia metodológica ha provocado una discrepancia continua entre los requerimientos reales de producción y el volumen de ventas. Dado que la administración manual impide el registro preciso de las pérdidas, se estableció una línea base diagnóstica mediante un muestreo piloto de observación directa y la aplicación del juicio experto operativo. Esta evaluación evidenció ineficiencias cuantificables críticas: por un lado, la sobrestimación de requerimientos genera una merma mensual del 12 % por caducidad de insumos y un 8 % de pérdidas por sobreproducción de bienes finales; por otro lado, la subestimación causa rupturas de stock constantes que se traducen en un 15 % de ventas perdidas. Adicionalmente, el tiempo de respuesta interno (lead time) para reponer el inventario oscila entre 48 y 72 horas en el mejor de los casos, generando una asimetría de información que encarece los costos operacionales fijos y degrada el nivel de servicio.

De mantener esa dinámica a mediano y largo plazo, la pastelería como organización se enfrenta a un riesgo de no seguir siendo sostenible financieramente. El margen de rentabilidad de la pastelería está siendo absorbido progresivamente por el doble impacto del costo de oportunidad derivado de las ventas perdidas y la descapitalización constante que genera la merma física, limitando la capacidad de reinversión de la empresa.

Para mitigar esta vulnerabilidad, es técnicamente y operativamente recomendable pasar del dato original al comportamiento efectivo mediante la implementación de técnicas de análisis predictivo.

La aplicación de algoritmos de Machine Learning permite identificar patrones subyacentes en el registro histórico de consumo y pronosticar con mayor precisión los niveles de demanda. Específicamente, los modelos de ensamble como el Random Forest, formalizado por Breiman (2001), han

demostrado una capacidad matemática superior para procesar la no linealidad y la alta dimensionalidad de los datos sin converger en el sobreajuste (Biau y Scornet, 2016). Esta capacidad analítica generada por el motor algorítmico se integrará en un tablero de control gerencial (dashboard) diseñado para automatizar las decisiones de abastecimiento. La finalidad es sustituir el modelo empírico actual mediante la generación de un punto de reorden evolutivo que aprenda continuamente del error de pronóstico, garantizando así la optimización del inventario.

1.2 OBJETIVOS DE LA INVESTIGACIÓN

1.2.1 Objetivo General

Proponer un sistema predictivo basado en Machine Learning para la optimización de inventarios perecederos de la industria repostería en la Pastelería Casserissima C.A., Maturín estado Monagas

1.2.2 Objetivos Específicos

- Diagnosticar los flujos de inventario y patrones de demanda actuales en la Pastelería Casserissima, para el establecimiento de los requerimientos lógicos necesarios en la automatización de los planes de compra.
- Entrenar el algoritmo de aprendizaje automático (*Random Forest*) para la captura de la estacionalidad de la demanda de productos perecederos, garantizando la precisión en la identificación de patrones de consumo.
- Elaborar el tablero de control gerencial e interfaz de usuario que integre un Punto de Reorden Evolutivo, facilitando el aprendizaje

continuo del error de pronóstico con base en métricas estadísticas (MAPE/RMSE).

- Validar la eficacia del sistema mediante una prueba retrospectiva (*Backtesting*), para la cuantificación de la disminución potencial de mermas y la optimización de los niveles de inventario en la organización.

1.3 JUSTIFICACIÓN DE LA INVESTIGACIÓN

La presente investigación encuentra su razón de ser en la necesidad crítica de cerrar la brecha tecnológica existente entre los métodos administrativos tradicionales y los estándares de analítica avanzada. Desde una perspectiva teórica, este estudio se justifica al validar la aplicación de arquitecturas de aprendizaje automático, específicamente el algoritmo de Random Forest, en el contexto de la pequeña industria alimentaria regional. Esta aproximación permite contrastar la consistencia matemática de los modelos de ensamble frente a las limitaciones de la estadística convencional y aporta conocimiento técnico sobre la capacidad de generalización de estos algoritmos ante datos complejos y entornos de alta volatilidad.

Asimismo, esta investigación establece un precedente para la automatización logística mediante el diseño de un tablero de control gerencial que integre un punto de reorden. De este modo, se propone una estructura lógica fundamentada en el aprendizaje continuo del error de pronóstico, lo cual ofrece un marco de trabajo replicable para otras unidades de producción que manejan bienes de corta vida útil. La relevancia socioeconómica del proyecto reside en el fortalecimiento de la viabilidad financiera de la empresa caserísima dentro de una economía compleja, puesto que promueve la eficiencia operativa y el aprovechamiento responsable de las materias primas en el sector repostero.

Bajo esta premisa, la optimización de los ciclos de abastecimiento trasciende el beneficio económico y genera un impacto directo en las dimensiones de sostenibilidad ambiental y seguridad integral. La acumulación excesiva de materia orgánica perecedera generada por los modelos de inventario empíricos se traduce en una alta tasa de desperdicio de alimentos.

La disposición final de estas mermas orgánicas en los vertederos municipales produce emisiones de gas metano que agudizan el efecto invernadero. De igual manera, el descarte de insumos degradados implica la pérdida irrecuperable de la huella hídrica y de carbono invertida a lo largo de toda la cadena de suministro alimentaria.

Por consiguiente, la implementación del motor predictivo incide favorablemente en los estándares de seguridad alimentaria y ocupacional de la organización. El mantenimiento de un inventario sobreabastecido de bienes de alta degradabilidad tales como insumos lácteos y ovoproducidos incrementa significativamente el riesgo de contaminación cruzada y la proliferación de patógenos en las áreas de almacenamiento. La erradicación de estos focos de descomposición protege la integridad biológica de las instalaciones, salvaguarda la salud del personal operativo ante riesgos sanitarios y garantiza la inocuidad del producto exigida por el consumidor final.

Finalmente, la estructuración de esta propuesta responde con rigurosidad a las exigencias teóricas del eje de Sistemas de Producción. Un modelo operativo verdaderamente eficiente no se circunscribe de manera exclusiva a la maximización de los márgenes de ganancia, sino que exige la reducción sistemática de las externalidades negativas derivadas de sus procesos. La integración del aprendizaje automático en Casserissima consolida un ecosistema de abastecimiento autónomo que armoniza la rentabilidad comercial con el respeto irrestricto por el medio ambiente y la seguridad industrial.

1.4 DELIMITACIÓN DE LA INVESTIGACIÓN

Desde la delimitación teórica, el estudio se fundamenta en la intersección de la gestión de operaciones y la analítica predictiva. Para el control de inventarios y la optimización de los sistemas de producción, el marco analítico toma como base los postulados clásicos de Riggs (2005). Por su parte, la estructuración del motor predictivo se rige estrictamente por los fundamentos matemáticos del aprendizaje automático (*Machine Learning*). De manera específica, la investigación aplica la arquitectura del algoritmo de *Random Forest* conceptualizada por Breiman (2001), la cual resulta idónea para modelar la estacionalidad y la volatilidad de la demanda en entornos estocásticos.

En cuanto a la delimitación metodológica, el estudio se enmarca en la modalidad de proyecto factible con un enfoque de investigación tecnológica, puesto que culmina en el desarrollo algorítmico y la propuesta de un tablero de control gerencial operativo para la organización. Para soportar esta arquitectura, la investigación se apoya en un diseño de campo, no experimental y transeccional. Esta decisión metodológica obedece a que el comportamiento de la demanda y los registros de las variables de inventario perecedero se recolectarán directamente de su entorno natural en el área de producción. Estos datos se observarán tal como se presentan, sin manipulación deliberada alguna, para garantizar la validez empírica del modelo.

Respecto a la delimitación espacial, el desarrollo lógico, la extracción de datos de entrenamiento y la evaluación retrospectiva del sistema se circunscriben específicamente a las instalaciones del área de almacén y producción de la Pastelería Casserissima C.A., unidad productiva ubicada en el sector Fundemos de la ciudad de Maturín, Estado Monagas.

Finalmente, la delimitación temporal establece que la recolección de los datos históricos, el entrenamiento del algoritmo y la formulación del modelo definitivo abarcan un lapso de ejecución de tres (3) meses continuos. Este periodo cronológico inicia en el mes de abril y concluye a finales del mes de junio del año 2026.

CAPÍTULO II

MARCO TEORICO

2.1 Antecedentes de la investigación

Los antecedentes son las investigaciones previas que se relacionan directamente con el objeto de estudio, constituyendo una base documental indispensable para sustentar el desarrollo de la investigación. En este sentido, se seleccionaron estudios internacionales y nacionales que aportan al diseño del sistema predictivo propuesto, solidez metodológica y contextual.

En el ámbito internacional, destaca el trabajo de Lira Pacheco y Tinoco Ricapa (2025), titulado: "Sistema basado en Machine Learning para predicción de inventarios para una empresa del sector industrial", presentado ante la Universidad Peruana de Ciencias Aplicadas (UPC) en Perú. La investigación tuvo como objetivo general implementar un sistema fundamentado en aprendizaje automático para la predicción de inventarios, con el fin de mitigar riesgos de desabastecimiento y sobrecostos por exceso de existencias. En cuanto a la metodología, el estudio se enmarca en un enfoque cuantitativo de tipo factible, empleando algoritmos de ensamble para el procesamiento de datos históricos de almacén.

Los resultados alcanzados mostraron una alta precisión en las estimaciones, lo que aseguró la consistencia de las predicciones en el entorno operativo. Los autores concluyeron que el cambio de métodos manuales a ecosistemas analíticos automatizados optimiza de forma significativa la trazabilidad del proceso logístico. Por ello, el presente trabajo toma la

investigación como referencia fundamental, ya que proporciona la arquitectura algorítmica necesaria para el diseño del motor predictivo en Casserissima.

Asimismo, se consultó el estudio de Afanador Jiménez et al. (2021)., denominado: "Diseño de un modelo de pronóstico de demanda basado en Machine Learning y un modelo multi-objetivo para planeación de la producción en una industria panificadora", realizado en la Pontificia Universidad Javeriana, Colombia. El propósito central fue diseñar un modelo técnico que permitiera armonizar los recursos disponibles con las fluctuaciones de la demanda en el sector alimentario. Desde la perspectiva metodológica, los investigadores aplicaron un diseño descriptivo y experimental, comparando métodos tradicionales frente a modelos de inteligencia artificial.

Los resultados demostraron que el aprendizaje automático supera las limitaciones de la planificación empírica, lo cual reduce las mermas de productos terminados en consecuencia, se concluyó que la estandarización de procesos mediante analítica predictiva es el factor determinante para la supervivencia financiera de empresas de bienes perecederos. Este antecedente guarda una estrecha relación con el estudio actual, ya que valida la eficacia del Machine Learning para resolver el problema de la caducidad crítica en el rubro repostero.

Finalmente, en el plano regional, se incorporó la investigación de Montes Meneses y Rivas (2022), titulada: "Plan de mejora para la calidad aplicado al proceso productivo de la panadería y pastelería D'Ivanna, en Maturín-Estado Monagas", presentada en la Universidad de Oriente (UDO), Núcleo de Monagas. El estudio se planteó como objetivo aplicar un plan de mejora para la calidad en los procesos de producción de una unidad repostera local. La metodología se definió como una investigación proyectiva de nivel

comprendivo, fundamentada en la Metodología de Sistemas Blandos y el uso de técnicas de programación extrema (XP). Los resultados permitieron obtener un prototipo de aplicación para el control de los requerimientos y la trazabilidad de los procesos.

Por lo tanto, los autores concluyeron que la sistematización de las operaciones manuales reduce la vulnerabilidad operativa ante las exigencias del mercado nacional. Este trabajo resulta de gran valor para la presente investigación, puesto que comparte el sector económico y la ubicación geográfica del caso de estudio, lo cual permite comprender las dinámicas comerciales específicas de Maturín y justifica la necesidad de proponer soluciones tecnológicas adaptadas al entorno regional.

2.2 Ubicación y Descripción del Área en Estudio

El presente trabajo de investigación se desarrolla en las instalaciones de la empresa Pastelería Casseríssima C.A., la cual se encuentra ubicada geográficamente en la ciudad de Maturín, Estado Monagas Fundemos transversal 9.

El área de estudio comprende el entorno operativo, comercial y administrativo del establecimiento. Esta organización funciona bajo la denominación de persona jurídica y su actividad principal está dedicada a la venta de tortas, postres y a la capacitación en el área de repostería. Asimismo, el espacio físico dispone de áreas de atención al cliente orientadas a la comercialización de productos complementarios que demanda su clientela.

Desde el punto de vista del talento humano que hace vida en el área de estudio, la dinámica operativa se sustenta en una plantilla conformada por tres (3) trabajadores. Dicha estructura organizativa es fundamental para los

procesos internos y se distribuye funcionalmente en los siguientes cargos: un propietario, un encargado y un vendedor. Es en este contexto físico, comercial y humano donde se llevará a cabo la recolección de los datos necesarios para diagnosticar la situación actual de los procesos en la empresa.

2.2.2 Reseña histórica de la empresa

La empresa Pastelería Casseríssima C.A. fue fundada el 23 de junio de 2023, registrada formalmente bajo el número de RIF J-50398310-8. Sus instalaciones se encuentran ubicadas en La Avenida Quiriquire, Casa Nro. 321, Urbanización Fundemos I (Zona Postal 6201), en la ciudad de Maturín, Estado Monagas. La organización se dedica principalmente a la elaboración, decoración y comercialización de tortas y productos de repostería. Bajo la dirección de su actual propietaria, Paola Valentina Otero Otero dueña de Casseríssima, la empresa ofrece una variada gama de productos complementarios que garantizan el funcionamiento y la rentabilidad continua del negocio.

A lo largo de su trayectoria, esta unidad productiva ha demostrado un compromiso constante que la ha hecho merecedora de una clientela fiel y consolidada con el pasar de los años. En respuesta a este crecimiento y a las exigencias del mercado actual, la organización busca incorporar nuevas herramientas tecnológicas y operativas orientadas a optimizar sus procesos internos y elevar los estándares de calidad en el servicio que ofrece.

2.2.3 Misión

La misión de Pastelería Casseríssima C.A. es satisfacer de manera integral las necesidades y expectativas de sus consumidores, proveedores y

colaboradores. Esto se logra a través de una gestión operativa eficiente y la elaboración de productos reposteros de la más alta calidad, garantizando siempre la competitividad en el mercado local y ofreciendo la mejor relación calidad-precio.

2.2.4 Visión

Posicionarse en el mercado regional de la repostería como la primera y mejor opción para los clientes. Para alcanzar este objetivo, la empresa se enfoca en la selección y formación continua de su talento humano, asegurando que cumplan con los perfiles requeridos y mantengan un compromiso absoluto con los valores de excelencia de la compañía.

2.2.5 Estructura organizativa

En la figura 1 se observa el organigrama de la empresa Tortas CASSERÍSSIMA C.A.




Figura 1. Organigrama de la empresa.

Fuente: Tortas CASSERISSÍMA, C.A.

2.3 BASES TEÓRICAS

Tal como señala Arias (2012), las bases teóricas comprenden un "conjunto de conceptos y proposiciones que constituyen un enfoque determinado, dirigido a explicar el problema planteado" (p. 106). Teniendo en cuenta esta base, la presente investigación sistematiza los ejes conceptuales y matemáticos necesarios para ejecutar la transición de un modelo logístico empírico hacia un ecosistema automatizado de soporte a las decisiones. Para alcanzar este propósito, el marco teórico se desglosa en tres dimensiones fundamentales: la gestión de inventarios perecederos, los algoritmos de analítica predictiva y la arquitectura de control gerencial.

Esta estructura jerárquica garantiza que la propuesta tecnológica para la pastelería Casserissima no solo sea computacionalmente robusta, sino también operativamente viable en el entorno productivo de Maturín.

2.3.1 Sistemas predictivos

El avance de las ciencias computacionales ha permitido la materialización de herramientas capaces de anticipar fluctuaciones operativas complejas mediante el estudio retrospectivo de la información. Al respecto, Shmueli y Koppius (2011) definen el análisis predictivo como el conjunto de métodos empíricos e inferenciales destinados a la extracción de conocimiento, con el propósito estricto de generar "predicciones empíricas sobre observaciones nuevas o futuras" (p. 554). Este enfoque metodológico trasciende la simple descripción estadística para orientarse hacia la construcción de modelos matemáticos que identifican patrones subyacentes dentro de vastos repositorios de datos históricos. Asimismo, la consecución de una ventaja técnica mediante estas metodologías demanda una rigurosidad analítica específica.

Provost y Fawcett (2013) sostienen que el modelado predictivo consiste en "una abstracción del mundo real de un proceso de negocio, creada para evaluar la probabilidad de un resultado específico bajo condiciones controladas" (p. 52). En consecuencia, la implementación de un sistema de esta índole requiere la transformación inicial de variables crudas en características significativas que alimenten algoritmos de aprendizaje automático, lo cual asegura la capacidad de generalización frente a escenarios inéditos.

Por consiguiente, la literatura especializada exige una validación paramétrica sistemática para garantizar la fiabilidad de las proyecciones emitidas en entornos de alta incertidumbre comercial. Bajo este orden de ideas, la integración de este marco de inferencia de datos resulta fundamental para el Desarrollo de un Sistema de Información basado en Machine Learning para la Optimización de Inventarios Perecederos. Específicamente, el motor predictivo algorítmico diseñado asimilará los registros continuos de demanda de la pastelería Casseríssima, lo cual permitirá proyectar con exactitud matemática los requerimientos de insumos futuros e impedirá tanto la ruptura de inventario comercial como el deterioro físico de la materia prima almacenada.

2.3.1.1 Tableros de control (dashboards)

La conceptualización de plataformas analíticas modernas demanda una interfaz que facilite la interpretación cognitiva de los resultados matemáticos generados por el núcleo de procesamiento. Sobre la base de la teoría de la visualización de la información, Few (2006) establece que un tablero de control constituye "una representación visual de la información más importante necesaria para lograr uno o más objetivos, consolidada y organizada en una sola pantalla" (p. 34). Dicha interfaz actúa como un puente de traducción semántica entre la alta complejidad algorítmica y el usuario humano, el cual aglomera métricas de rendimiento continuo en un formato de rápida asimilación. Para robustecer esta perspectiva operativa, es imperativo considerar la utilidad directiva de estas herramientas en el ámbito empresarial.

Eckerson (2010) argumenta que estos sistemas de visualización representan "aplicaciones de inteligencia de negocios en capas que traducen la estrategia corporativa en métricas accionables" (p. 17). En consecuencia, el

diseño arquitectónico de estos paneles exige una jerarquización meticulosa de las variables para mitigar la sobrecarga sensorial del operador en el momento de la lectura. Por consiguiente, el despliegue gráfico debe omitir sistemáticamente los elementos visuales superfluos, lo cual prioriza la claridad absoluta de los indicadores logísticos y transforma volúmenes masivos de datos procesados en conocimiento estratégico de forma instantánea.

Acoplado esta triangulación teórica a las exigencias operacionales de la pastelería Casseríssima, la materialización del sistema informático requerirá la programación de un panel interactivo. Este entorno visual consolidará de manera perpetua las salidas del modelo predictivo, lo cual otorgará al gerente general una estación centralizada para monitorear las alertas de reabastecimiento crítico y habilitará la ejecución de compras estratégicas sin demandar experiencia técnica en la disciplina de la ciencia de datos. Para ilustrar la convergencia de estas directrices arquitectónicas, la Figura 2 expone el diseño conceptual propuesto para la interfaz, donde se prioriza la visualización de las métricas estocásticas y la generación de alertas accionables de inventario.




Figura 2. Prototipo de la interfaz del tablero de control gerencial orientado a la optimización de insumos críticos
Fuente: Elaboración propia (2026).

2.3.2 Machine learning (aprendizaje automático)

La disciplina de la inteligencia artificial ha evolucionado hacia la creación de arquitecturas computacionales capaces de inferir conocimiento abstracto sin demandar una intervención programática explícita. Al respecto, Mitchell (1997) postula que el aprendizaje automático ocurre cuando un sistema informático "aprende de la experiencia E con respecto a alguna clase de tareas T y medida de rendimiento P, si su rendimiento en T mejora con la experiencia E" (p. 2). Esta capacidad de adaptación empírica representa una ruptura epistemológica con la programación procedimental tradicional, ya que sustituye la codificación de reglas rígidas por la asimilación algorítmica de patrones.

En este orden de ideas, Alpaydin (2020) argumenta que esta tecnología constituye "la programación de computadoras para optimizar un criterio de rendimiento utilizando datos de ejemplo o experiencia pasada" (p. 3). Asimismo, Romero (2021) sostiene que este enfoque resulta indispensable para la toma de decisiones empresariales, puesto que adopta arquitecturas diseñadas para identificar tendencias ocultas en grandes volúmenes de información. En consecuencia, la implementación de estos paradigmas analíticos exige la recolección exhaustiva de datos históricos para calibrar redes matemáticas complejas. Por consiguiente, el modelo resultante adquiere la facultad de generalizar estructuras lógicas ocultas frente a estímulos no observados previamente, lo cual disminuye la varianza de las predicciones a lo largo del tiempo.

Bajo esta premisa, la integración de esta rama científica resulta imperativa para el desarrollo de un sistema de información basado en *Machine Learning* orientado a la optimización de inventarios perecederos. Específicamente, el núcleo del motor predictivo asimilará los volúmenes históricos de ventas de la Pastelería Casseríssima, lo cual dotará al entorno digital de la capacidad analítica necesaria para anticipar el comportamiento estocástico de la demanda e impedirá la obsolescencia de los insumos almacenados.

2.3.2.1 Algoritmo random forest

Dentro del espectro de técnicas de aprendizaje supervisado, los métodos de ensamble destacan por su resistencia algorítmica frente a la inestabilidad predictiva de los estimadores individuales. Sobre la base de la teoría de partición recursiva, Breiman (2001) define el algoritmo Random Forest como "un clasificador que consiste en una colección de predictores estructurados en forma de árbol, donde cada árbol depende de los valores de un vector aleatorio muestreado de forma independiente" (p. 5). Esta forma de estructurar las decisiones opera bajo el principio estadístico de la sabiduría de las multitudes, lo cual mitiga el sobreajuste inherente a la construcción de árboles de decisión solitarios y excesivamente profundos.

Asimismo, la configuración de esta red demanda un enfoque de agregación de la varianza. Sobre este aspecto, Hastie, Tibshirani y Friedman (2009) sostienen que esta técnica encarna "una modificación sustancial del ensamblaje que construye una vasta colección de árboles des correlacionados y luego los promedia" (p. 587). La inyección de aleatoriedad estocástica, tanto en la selección de instancias mediante reemplazo como en la partición de los nodos, genera una matriz predictiva altamente tolerante al ruido en los datos. Para ilustrar de manera gráfica la estructura interna de este proceso se presenta la Figura 3.




Figura 3. Arquitectura predictiva y flujo de decisión del algoritmo Random Forest.

Fuente: Abbasimehr y Shabani (2021)

Acoplando este fundamento teórico a la realidad operativa del proyecto, el ensamble Random Forest fungirá como el núcleo procesador del sistema para la pastelería Casseríssima. Su arquitectura algorítmica procesará las fluctuaciones cíclicas de la clientela y el impacto de las festividades locales, lo cual generará proyecciones de demanda de altísima precisión para los productos perecederos y garantizará un reabastecimiento logístico ininterrumpido.

2.3.2.2 Métricas de evaluación (MAPE y RMSE)

La rigurosidad del modelado estadístico exige la cuantificación objetiva y continua del error de inferencia para validar la fiabilidad de las proyecciones algorítmicas. En el ámbito de la predicción temporal, Hyndman y Koehler (2006) establecen que el Error Porcentual Absoluto Medio (MAPE) posee "la ventaja de ser independiente de la escala, por lo que se utiliza frecuentemente para comparar el rendimiento de las previsiones en diferentes series de datos" (p. 681). Esta tasa porcentual facilita la asimilación cognitiva de la desviación estándar para los actores corporativos. No obstante, la complementariedad de los indicadores de evaluación penaliza la interpretación sesgada del rendimiento del sistema ante valores atípicos.

Chai y Draxler (2014) argumentan que la Raíz del Error Cuadrático Medio (RMSE) constituye "una métrica de precisión estándar que otorga un peso relativamente alto a los errores de gran magnitud" (p. 1248). En consecuencia, la convergencia de ambas ecuaciones proporciona un escrutinio holístico de la desviación del modelo; mientras el MAPE expresa las desviaciones operativas regulares de forma escalable, el RMSE castiga algebraicamente las anomalías predictivas extremas.

Para ilustrar la pertinencia operativa de esta dualidad métrica en la Pastelería Casseríssima, resulta imperativo proyectar el comportamiento de un insumo crítico y de alta rotación, como los cartones de huevos. En un escenario donde el algoritmo de *Machine Learning* subestime de forma severa un pico de demanda atípico, el impacto logístico generaría una ruptura de *stock* capaz de paralizar las líneas de horneado. La Figura 4 modela esta desviación, lo cual evidencia cómo un fallo predictivo grave dispara el valor del

RMSE para alertar a la gerencia, aun cuando el promedio del MAPE se mantenga visualmente estable.




Figura 4. Análisis comparativo de la demanda real frente al pronóstico de cartones de huevos y su impacto en las métricas de error (MAPE y RMSE).

Fuente: Elaboración propia (2026).

Por consiguiente, la validación paramétrica del sistema informático requiere la minimización simultánea de ambas funciones de pérdida. Bajo este orden de ideas, el despliegue del modelo dentro de la pastelería Casseríssima se sustentará empíricamente mediante el cálculo iterativo de estos dos estimadores. La tabulación final de estas métricas demostrará numéricamente que la arquitectura construida supera las heurísticas de inventario tradicionales, lo cual confirmará su pertinencia analítica para optimizar la cadena de suministro sin incurrir en pérdidas financieras por mermas caducas.

2.3.3 Optimización de inventarios perecederos

La administración de recursos logísticos enfrenta un desafío crítico cuando los bienes almacenados poseen una vida útil finita, una condición que exige la supresión matemática de la intuición humana. Al respecto, Nahmias (2011) establece que un inventario perecedero comprende "cualquier producto que pierde su valor o utilidad a lo largo del tiempo, ya sea de forma repentina tras una fecha de caducidad o mediante un deterioro físico continuo" (p. 15). La gestión de estos insumos exige una sincronización algorítmica exacta entre el aprovisionamiento y el consumo del mercado. Silver et al. (2016) sostienen que el control de estos bienes requiere "políticas de reposición dinámicas que minimicen los costos conjuntos de escasez, mantenimiento y obsolescencia bajo condiciones de demanda estocástica" (p. 385).

Asimismo, la ingeniería industrial moderna sustituye las heurísticas tradicionales de compra por modelos cuantitativos capaces de calcular la degradación de la materia prima en tiempo real. En consecuencia, la parametrización de las caducidades transforma la vulnerabilidad física de los productos en una restricción de diseño dentro de los algoritmos de reposición. Por consiguiente, la maximización del beneficio operativo depende de la capacidad del sistema para anticipar las fluctuaciones del consumo antes de que ocurra la pérdida irrecuperable del capital invertido.

La aplicación estricta de estos preceptos teóricos resulta indispensable para el Desarrollo de un Sistema de Información basado en Machine Learning para la Optimización de Inventarios Perecederos. Específicamente, la arquitectura analítica gestionará el flujo de materias primas de la pastelería Casseríssima, lo cual impedirá el desperdicio financiero derivado de la merma de ingredientes orgánicos y garantizará la frescura ininterrumpida de sus elaboraciones comerciales.

2.3.3.1 Sistema de clasificación ABC

En la disciplina de la gestión de operaciones, la heterogeneidad física y financiera de los bienes almacenados impide la aplicación de una política de control uniforme sobre la totalidad del catálogo. Al respecto, Heizer y Render (2014) establecen que el análisis ABC constituye "un método para dividir el inventario disponible en tres clases en función del volumen anual en dólares" (p. 490). Esta segregación jerárquica se fundamenta empíricamente en el principio de Pareto, el cual dictamina que una fracción minúscula de los artículos concentra la inmensa mayoría del valor económico o del riesgo de pérdida dentro de una organización. Asimismo, la asignación de la capacidad de procesamiento informático exige focalizar el esfuerzo matemático estrictamente en las referencias más críticas.

Silver et al. (2016) argumentan que los artículos pertenecientes a la categoría superior demandan "los sistemas de control más rigurosos, revisiones continuas y pronósticos detallados de la demanda" (p. 45). En consecuencia, la discriminación metodológica de los insumos exige a la gerencia de aplicar modelos estocásticos complejos a bienes de bajo impacto logístico, lo cual optimiza la carga computacional del software. Por consiguiente, esta clasificación actúa como un filtro estructural ineludible antes

de ejecutar cualquier estimador predictivo en un entorno de recursos limitados. Bajo este orden de ideas, la integración de este marco conceptual resulta vital para delimitar el alcance del Desarrollo de un Sistema de Información basado en Machine Learning para la Optimización de Inventarios Perecederos.

El sistema segmentará el catálogo total de la pastelería Casseríssima para aislar y priorizar los insumos críticos. Bajo este enfoque, se catalogarán como artículos de Clase A tanto los insumos orgánicos de vida útil efímera (huevos, cremas lácteas y frutas frescas) como aquellos bienes de consumo masivo que, pese a poseer una caducidad más prolongada, concentran el mayor volumen financiero y presentan una alta vulnerabilidad a la merma por contaminación biológica o humedad (harina de trigo). Esta maniobra técnica justificará matemáticamente la aplicación exclusiva del algoritmo *Random Forest* sobre este subconjunto estratégico, lo cual impedirá el desperdicio de recursos computacionales en mercancía de bajo impacto logístico correspondiente a las Clases B y C.

2.3.3.2 Método FIFO (primeras entradas, primeras salidas)

La rotación sistemática del inventario constituye la primera barrera operativa contra la degradación irreversible de los recursos físicos dentro de un almacén. En el ámbito de la administración de operaciones, Heizer y Render (2014) definen el método FIFO como "una política de despachos donde los artículos más antiguos en el inventario son los primeros en ser utilizados o vendidos" (p. 502). Esta regla de prioridad secuencial regula el flujo logístico y previene el estancamiento de lotes próximos a su límite biológico o comercial.

Para expandir el impacto financiero de esta normativa, Krajewski et al. (2013). Argumentan que esta disciplina logística asegura que "el costo de los bienes vendidos refleje los precios de los materiales más antiguos, mientras que el inventario final valora las adquisiciones más recientes" (p. 421). Debido a esto, la observancia de este protocolo estabiliza la contabilidad de costos en economías sujetas a alta inflación o volatilidad de precios. En consecuencia, el diseño estructural de las cámaras de refrigeración debe forzar físicamente la extracción de los insumos según su antigüedad cronológica. Cualquier desviación de este principio acelera exponencialmente las tasas de deterioro e invalida la precisión de los pronósticos de demanda.

Acoplando este fundamento a las exigencias operacionales del proyecto, el sistema de información integrará la lógica FIFO como una restricción ineludible dentro de su código fuente. Esta configuración lógica forzará al personal de la pastelería Casseríssima a extraer y consumir los insumos alimenticios en su orden estricto de llegada, lo cual erradicará la caducidad oculta en los anaqueles y optimizará el flujo de materiales del establecimiento.

2.3.3.3 Modelo Newsvendor (vendedor de periódicos)

La toma de decisiones corporativas bajo entornos de alta incertidumbre demanda un equilibrio matemático estricto entre la penalización por sobreoferta y el costo de oportunidad del desabastecimiento. Sobre la base de la teoría estocástica de inventarios, Cachon y Terwiesch (2013) postulan que el modelo Newsvendor busca "encontrar la cantidad de pedido que maximiza el beneficio esperado equilibrando el costo de pedir demasiado frente al costo de pedir muy poco" (p. 291). La utilidad de este teorema probabilístico se materializa al procesar distribuciones empíricas de ventas para bienes de ciclo vital corto.

Al respecto, Chopra y Meindl (2016) establecen que la cantidad óptima de disponibilidad en un solo período se alcanza cuando "la probabilidad de que la demanda sea menor o igual al pedido iguala la relación del costo de faltante sobre la suma de los costos de faltante y exceso" (p. 352). Asimismo, la resolución de esta fórmula algebraica somete la agresividad comercial de la gerencia a un escrutinio de riesgo estadístico puro. En consecuencia, el modelo castiga numéricamente la retención excesiva de productos que perderán su valor al finalizar el día de operaciones. Por consiguiente, la adopción de este paradigma erradica la dependencia emocional del comprador empírico, lo cual sustituye el miedo a la ruptura de stock por una política de suministro matemáticamente sustentable.

Para ilustrar la mecánica de este teorema, resulta pertinente modelar el comportamiento estocástico de un insumo de alta sensibilidad térmica y caducidad acelerada, como las cremas y coberturas. La Figura 5 proyecta la curva de densidad de probabilidad de la demanda para este rubro. El área sombreada representa la "Razón Crítica" (el equilibrio exacto entre el costo de exceso y costo de escasez), lo cual determina el punto de corte vertical que dicta la Cantidad Óptima de Pedido (Q^*). Visualmente, se demuestra que el inventario no se repone en función del promedio, sino del nivel de servicio financiero que maximiza la utilidad.




Figura 5. Curva de distribución de demanda y determinación de la Cantidad Óptima de Pedido (Q^*) bajo el Modelo Newsvendor para cremas y coberturas.

Fuente: Elaboración propia (2026).

Bajo este orden de ideas, esta ecuación actuará como el decodificador financiero principal dentro del motor predictivo diseñado. El sistema ingerirá las proyecciones generadas por el algoritmo Random Forest y utilizará la formulación del Newsvendor para calcular la cantidad exacta de cremas y coberturas que la pastelería Casseríssima debe solicitar a sus proveedores, lo cual neutralizará simultáneamente la pérdida por ventas no realizadas y el costo destructivo de la merma caduca.

2.3.3.4 Indicadores de gestión logística (KPIs)

La auditoría retrospectiva y continua de las operaciones industriales exige la parametrización de métricas objetivas que evalúen la eficiencia terminal de la cadena de suministro. En la disciplina del desempeño corporativo, Parmenter (2015) define los indicadores clave de rendimiento como "un conjunto de medidas enfocadas en aquellos aspectos del desempeño organizacional que son más críticos para el éxito actual y futuro del negocio" (p. 3). La traslación de esta doctrina gerencial hacia el control de almacenes requiere la captura en tiempo real de los índices de deterioro y disponibilidad.

Bowersox et al. (2013). Sostienen que el desempeño operativo logístico se cuantifica estrictamente mediante "el nivel de servicio al cliente, entendido como la tasa de cumplimiento de pedidos sin incidentes, y el costo total de la logística, el cual incluye las mermas del inventario" (p. 55). Asimismo, la monitorización matemática de estas fracciones expone las deficiencias ocultas en las políticas de reabastecimiento. En consecuencia, una interfaz analítica debe recopilar estos datos de forma autónoma, sin tolerar la manipulación de los registros manuales.

Por consiguiente, la lectura conjunta del índice de rotura de stock frente al porcentaje de productos desechados otorga a la directiva una radiografía irrefutable de la salud financiera del inventario. La arquitectura del software desarrollado calculará el índice de mermas orgánicas y la tasa de nivel de servicio logístico de manera ininterrumpida. La lectura de estos KPIs demostrará estadísticamente cómo el modelo predictivo supera los métodos empíricos previos, lo cual validará el impacto del sistema sobre la rentabilidad de la pastelería Casseríssima y blindará su defensa de tesis.

2.3.4 Industria repostería

El sector gastronómico especializado demanda una sincronización rigurosa entre la manufactura de los bienes y su comercialización inmediata. Al respecto, Davis et al. (2018). Establecen que la industria de alimentos y bebidas constituye "un sector manufacturero complejo donde la transformación de materias primas perecederas debe sincronizarse exactamente con los patrones de demanda del consumidor" (p. 22). Esta exigencia operativa se agudiza inexorablemente en la elaboración de postres y productos horneados.

Gisslen (2017) argumenta que la repostería profesional representa "un proceso científico en el cual los ingredientes interactúan químicamente bajo condiciones térmicas y de proporciones estrictamente controladas" (p. 5). En consecuencia, la viabilidad financiera de estos establecimientos depende de la capacidad gerencial para alinear el abastecimiento de formulaciones delicadas con un consumo final altamente estocástico. Por consiguiente, el margen de error logístico en este tipo de manufactura es matemáticamente nulo frente a la degradación biológica de los materiales.

La comprensión de esta dinámica industrial resulta obligatoria para fundamentar el Desarrollo de un Sistema de Información basado en Machine Learning para la Optimización de Inventarios Perecederos. Específicamente, el motor predictivo se acoplará a la realidad comercial de la pastelería Casseríssima, lo cual transformará la gestión empírica de sus vitrinas en un proceso de abastecimiento algorítmico y protegerá el capital invertido frente a la volatilidad de los clientes locales.

2.3.4.1 Gestión de insumos críticos y mermas

La administración de componentes orgánicos vulnerables constituye el núcleo de la rentabilidad en la manufactura de alimentos. En el ámbito del control financiero gastronómico, Dopson y Hayes (2015) sostienen que la gestión de inventarios críticos exige "el monitoreo continuo de ingredientes de alto riesgo y corta vida útil para evitar variaciones negativas en el margen de beneficio" (p. 112). Esta vulnerabilidad intrínseca caracteriza a insumos base como lácteos, huevos y harinas, cuya ventana de utilidad se extingue aceleradamente. Asimismo, el fracaso en la rotación de estos elementos genera un pasivo económico destructivo para la organización.

Sobre este aspecto Parfitt et al. (2010). Argumentan que las mermas orgánicas representan "una ineficiencia terminal en la cadena de suministro que destruye simultáneamente valor económico y capacidad operativa" (p. 3065). Debido a esto, la obsolescencia de los ingredientes trasciende la simple pérdida material para convertirse en una hemorragia de liquidez corporativa. En consecuencia, la contención de este fenómeno logístico exige metodologías analíticas superiores a la observación humana.

Por consiguiente, la erradicación de las mermas requiere proyectar el agotamiento exacto de los recursos antes de su descomposición física. Acoplado esta fundamentación a la ejecución de su investigación, el modelo Random Forest asimilará el comportamiento histórico de los insumos críticos dentro de la pastelería Casseríssima. La arquitectura predictiva calculará el ciclo de vida de los lácteos, frutas y cremas, lo cual impedirá el sobreabastecimiento de la cámara de refrigeración y erradicará el impacto financiero negativo provocado por la caducidad oculta de estas materias primas.

2.4 BASES LEGALES

El basamento legal de la presente investigación se sustenta en el ordenamiento jurídico venezolano vigente, el cual avala el desarrollo tecnológico, la protección de los datos y la optimización de los procesos productivos. En este sentido, el estudio se rige por las siguientes normativas:

2.4.1 Constitución de la República Bolivariana de Venezuela (1999)

Publicada en la Gaceta Oficial N° 5.908 Extraordinario, de fecha 19 de febrero de 1999. En su capítulo VI, referente a los derechos económicos, establece los principios que rigen la actividad productiva y tecnológica en el país:

Artículo 110. El Estado reconocerá el interés público de la ciencia, la tecnología, el conocimiento, la innovación y sus aplicaciones y los servicios de información necesarios por ser instrumentos fundamentales para el desarrollo económico, social y político del país, así como para la seguridad y soberanía nacional (...)

Artículo 112. Todas las personas pueden dedicarse libremente a la actividad económica de su preferencia, sin más limitaciones que las previstas en esta Constitución y las que establezcan las leyes (...)

Artículo 117. Todas las personas tendrán derecho a disponer de bienes y servicios de calidad, así como a una información adecuada y no engañosa sobre el contenido y características de los productos y servicios que consumen (...)

Los artículos expuestos amparan constitucionalmente la ejecución de este proyecto. El Artículo 110 justifica la implementación de algoritmos de *Machine Learning* como un instrumento de innovación tecnológica para el

desarrollo comercial. Asimismo, los Artículos 112 y 117 respaldan el derecho de la Pastelería Casseríssima a ejercer su actividad económica buscando la máxima eficiencia, obligándola simultáneamente a garantizar productos de alta calidad al consumidor, lo cual se logra directamente al evitar el uso de insumos caducados mediante el control estricto del inventario.

2.4.2 Ley Orgánica del Sistema Venezolano para la Calidad (2002)

Publicada en la Gaceta Oficial Extraordinaria N° 37.543, de fecha 23 de octubre de 2002. En su Título I (Disposiciones Generales), establece los lineamientos para garantizar la calidad de bienes y servicios:

Artículo 5. Las personas naturales o jurídicas, públicas o privadas, que produzcan bienes, o presten servicios sujetos a reglamentaciones técnicas, o los comercialicen, deberán suministrar la información y la documentación necesaria que permita la posterior comprobación de la calidad de los mismos (...)

Artículo 6. Las personas naturales o jurídicas, públicas o privadas, están obligadas a proporcionar bienes y prestar servicios de calidad. Estos bienes y servicios deberán cumplir con las reglamentaciones técnicas que a tal efecto se dicten (...)

Esta normativa fundamenta la pertinencia operativa del sistema predictivo propuesto. Para que la pastelería cumpla con la obligación de ofrecer bienes de calidad (Artículo 6), resulta imperativo mantener un monitoreo riguroso sobre la frescura de la materia prima. El tablero de control gerencial propuesto automatiza esta documentación y trazabilidad (Artículo 5), garantizando que las políticas de rotación FIFO se cumplan bajo estándares técnicos precisos y no bajo estimaciones empíricas.

2.4.3 Ley Orgánica de Seguridad y Soberanía Agroalimentaria (2008)

Publicada en Gaceta Oficial Extraordinaria N° 5.889, de fecha 31 de julio de 2008. Regula el manejo responsable de los recursos alimentarios en la nación:

Artículo 104. Todas las personas naturales o jurídicas, públicas o privadas, están obligadas a evitar el desperdicio de alimentos y la generación de mermas orgánicas que atenten contra la disponibilidad alimentaria.

Este estatuto constituye el soporte legal directo del problema de investigación abordado. El diseño del algoritmo *Random Forest* acoplado al modelo matemático de inventario (*Newsvendor*) tiene como fin último la mitigación de las rupturas de stock y la prevención del deterioro físico de los insumos. En consecuencia, el sistema proyectado garantiza que la organización cumpla estrictamente con la obligación de erradicar el desperdicio de materia prima orgánica.

2.4.4 Ley Especial Contra los Delitos Informáticos (2001)

Publicada en Gaceta Oficial N° 37.313, de fecha 30 de octubre de 2001. Regula la protección de los sistemas que utilizan tecnologías de la información:

Artículo 6. El que sin la debida autorización o excediendo la que hubiere obtenido, acceda, intercepte, interfiera o use un sistema que utilice tecnologías de información, será penado con prisión de uno a cinco años y multa de diez a cincuenta unidades tributarias.

Dado que la investigación culmina en el desarrollo e implementación de una plataforma de *software* (tablero de control), se hace indispensable considerar el marco jurídico de la seguridad informática. Este artículo exige el diseño de protocolos de control de acceso y autenticación en la interfaz del sistema, con el propósito de restringir la manipulación de los registros de inventario exclusivamente al personal autorizado, salvaguardando así la integridad de los datos de la empresa.

2.5 DEFINICIÓN DE TÉRMINOS BÁSICOS

Abastecimiento: Es el proceso de asegurar que los materiales, suministros y servicios necesarios estén disponibles para las operaciones de una organización en el momento oportuno y al menor costo posible (Ballou, 2004, p. 55).

Algoritmo: Se define como un conjunto finito de reglas o pasos bien definidos, ordenados y finitos que permiten llevar a cabo una actividad mediante pasos sucesivos que no generen dudas a quien deba realizar dicha actividad (Brassard y Bratley, 1997, p. 2).

Analítica Predictiva: Consiste en el uso de datos, algoritmos estadísticos y técnicas de aprendizaje automático para identificar la probabilidad de resultados futuros basados en datos históricos (Siegel, 2013, p. 12).

Aprendizaje Automático (Machine Learning): Es el campo de estudio que otorga a las computadoras la capacidad de aprender sin ser programadas explícitamente, centrándose en el desarrollo de programas que pueden cambiar cuando se exponen a nuevos datos (Mitchell, 1997, p. 2).

Bosques Aleatorios (Random Forest): Algoritmo de aprendizaje supervisado que consiste en una combinación de árboles de decisión de tal manera que cada árbol depende de los valores de un vector aleatorio probado de forma independiente y con la misma distribución para todos los árboles del bosque (Breiman, 2001, p. 5).

Demanda Estocástica: Aquella demanda de artículos que es aleatoria y no se conoce con certeza, pero cuya distribución de probabilidad puede ser estimada mediante métodos estadísticos (Hillier y Lieberman, 2010, pág. 772).

Estacionalidad: Componente de una serie temporal que representa una variación periódica y repetitiva que ocurre en intervalos de tiempo regulares, generalmente menores a un año (Box et al., 2015, p. 23)

Inventario Perecedero: Existencias cuya utilidad o valor disminuye con el tiempo debido a la degradación física o la obsolescencia, requiriendo modelos de gestión específicos para evitar su pérdida total (Silver, Pyke y Peterson, 1998, p. 396).

CAPÍTULO III

MARCO METODOLÓGICO

El marco metodológico constituye la columna vertebral procedimental de toda investigación científica, ya que establece el camino sistemático a través del cual se alcanzarán los objetivos formulados. Tal como señala Arias (2012), la metodología comprende el conjunto de pasos, técnicas y procedimientos que se emplean para formular y resolver el problema de investigación. En consecuencia, el presente capítulo define el tipo, el nivel y el diseño de la investigación, así como la población y muestra, las técnicas e instrumentos de recolección y análisis de datos, y el diseño operativo que guiará el desarrollo del sistema predictivo basado en Machine Learning para la optimización de inventarios perecederos en la Pastelería Casserissima, Maturín, Estado Monagas.

3.1 TIPO DE INVESTIGACIÓN

La presente investigación se clasifica como de tipo proyectiva, apoyada en fuentes de campo y documentales. Según Hurtado (2010), la investigación proyectiva consiste en la elaboración de una propuesta o modelo como solución a un problema o necesidad de tipo práctico, a partir del diagnóstico preciso de las necesidades del momento, los procesos explicativos o generadores involucrados y las tendencias futuras. Esta clasificación resulta pertinente dado que el estudio no se limita a describir la situación actual de la gestión de inventarios en la Pastelería Casserissima, sino que avanza hacia el diseño y la propuesta de un sistema predictivo fundamentado en el algoritmo de Random Forest, capaz de automatizar la toma de decisiones logísticas.

Asimismo, la investigación se apoya en un enfoque de campo, puesto que los datos primarios se recaban directamente en las instalaciones de la empresa objeto de estudio, tal como lo establece Arias (2012) al definir la investigación de campo como aquella que consiste en la recolección de datos directamente de los sujetos investigados o de la realidad donde ocurren los hechos. Paralelamente, se integra el componente documental, en tanto que la construcción del marco teórico y la justificación metodológica del algoritmo seleccionado requieren la revisión sistemática de publicaciones científicas especializadas, trabajos de investigación precedentes y literatura técnica sobre aprendizaje automático y gestión de inventarios perecederos.

La combinación de estos tres tipos garantiza que la propuesta tecnológica resultante no sea un ejercicio teórico abstracto, sino una solución fundamentada en la realidad operativa de la organización, coherente con el estado del arte científico y orientada a generar un impacto tangible en la eficiencia logística de la pastelería.

3.2 NIVEL DE LA INVESTIGACIÓN

En cuanto al nivel de profundidad, esta investigación se ubica en el nivel comprensivo o explicativo-proyectivo. De acuerdo con Hurtado (2010), este nivel trasciende la simple descripción de los hechos para adentrarse en el análisis de las causas, las relaciones entre variables y la formulación de propuestas concretas de mejora. La investigación no solo diagnostica las deficiencias en la gestión de inventarios de la Pastelería Casserissima, sino que identifica los factores explicativos de dichas deficiencias y propone, a partir de ese análisis causal, un sistema predictivo que las atienda de manera integral.

En una primera etapa, el estudio adopta un nivel descriptivo al caracterizar los flujos actuales de inventario, los patrones históricos de demanda y los métodos empíricos utilizados por el personal de almacén. Posteriormente, la investigación avanza hacia un nivel explicativo al establecer las relaciones entre la alta volatilidad de la demanda, la corta vida útil de los insumos y el origen de las mermas operativas. Finalmente, el nivel proyectivo se concreta en el diseño del motor algorítmico de Random Forest y del tablero de control gerencial con Punto de Reorden Evolutivo.

Esta progresión metodológica por niveles garantiza que la solución tecnológica propuesta responda a causas comprendidas con rigor científico y no a suposiciones intuitivas, lo cual dota a la investigación de una solidez epistemológica coherente con los estándares académicos de la Universidad de Oriente, Núcleo de Monagas.

3.3 DISEÑO DE LA INVESTIGACIÓN

El diseño de la investigación es no experimental, de corte transversal. Según Hernández, Fernández y Baptista (2014), en el diseño no experimental las variables no son manipuladas deliberadamente por el investigador; en cambio, se observan los fenómenos tal y como ocurren en su contexto natural. En este caso, la demanda de productos perecederos, los niveles de inventario y los registros históricos de ventas son observados y analizados sin intervención directa sobre las operaciones de la pastelería.

El carácter transversal implica que la recolección de datos se realiza en un período de tiempo delimitado, comprendido entre los meses de abril y junio de 2026, tal como fue establecido en la delimitación de la investigación. Este período de tres meses permite capturar variaciones estacionales representativas del comportamiento comercial de la pastelería, sin que la investigación se extienda a un seguimiento longitudinal de largo plazo.

Adicionalmente, el diseño incorpora una fase de simulación retrospectiva (backtesting), mediante la cual el modelo entrenado se evalúa sobre ventanas temporales históricas ya ocurridas. Esta técnica, ampliamente utilizada en la evaluación de modelos de pronóstico de series temporales, permite cuantificar la eficacia del sistema predictivo sin necesidad de esperar resultados futuros, lo que la hace metodológicamente idónea para el alcance temporal de este estudio.

3.4 POBLACIÓN Y MUESTRA

3.4.1 Población

En el contexto de la presente investigación, la población se concibe desde dos dimensiones complementarias: la población humana y la población de datos. Con respecto a la primera, Arias (2012) define la población como "un conjunto finito o infinito de elementos con características comunes para los cuales serán extensivas las conclusiones de la investigación" (p. 81). Desde esta perspectiva, la población humana está constituida por la totalidad del personal directivo y operativo vinculado a la gestión de inventarios y la toma de decisiones de compra en la Pastelería Casserissima, conformada por tres

(3) personas: la gerente general, la encargada de almacén y el responsable de producción.

En cuanto a la población de datos, esta comprende la totalidad de los registros históricos de ventas diarias, entradas de insumos y salidas de materiales almacenados en hojas de cálculo de Microsoft Excel por la organización durante el período correspondiente a los tres meses de recolección definidos en la delimitación de la investigación (abril a junio de 2026).

3.4.2 Muestra

Dada la reducida dimensión de la población humana, se aplica un muestreo no probabilístico intencional o censal, lo que implica que la totalidad de los sujetos que conforman la población serán incluidos en el proceso de recolección de información. Tal como sostiene Ramírez (1997), en aquellos estudios donde la población es pequeña y accesible, es metodológicamente recomendable trabajar con todos los sujetos disponibles, garantizando así la representatividad total. En consecuencia, las tres personas identificadas serán entrevistadas en su totalidad.

En lo que respecta a la muestra de datos, el conjunto de registros históricos extraídos de las hojas de cálculo constituirá el dataset de entrenamiento y validación del modelo predictivo. Este dataset será sometido a un proceso de depuración, normalización e ingeniería de características que garantice su calidad estadística. Dado que el período de recolección abarca noventa días de operación, se estima contar con un volumen suficiente de observaciones diarias para entrenar el algoritmo de Random Forest con la

robustez matemática que este requiere, conforme a los criterios establecidos por Breiman (2001) y Biau y Scornet (2016).

3.5 TÉCNICAS E INSTRUMENTOS DE RECOLECCIÓN DE DATOS

Para garantizar la triangulación metodológica y la validez de la información recabada, la presente investigación emplea tres técnicas de recolección de datos, cada una asociada a un instrumento específicamente diseñado para los propósitos del estudio. Según Arias (2012), la técnica es el procedimiento o forma particular de obtener datos o información, mientras que el instrumento es cualquier recurso, dispositivo o formato —en papel o digital— que se utiliza para registrar la información obtenida.

3.5.1 Observación Directa

La observación directa es una técnica mediante la cual el investigador presencia y registra los hechos de interés de manera sistemática y planificada en su entorno natural, sin interferir en el desarrollo normal de las actividades observadas (Arias, 2012). En el contexto de la presente investigación, se realizarán visitas estructuradas a las instalaciones de la Pastelería Casserissima con el propósito de examinar in situ el ciclo completo de gestión de inventarios: recepción de insumos perecederos, condiciones y criterios de almacenamiento, despacho a producción y registro de las mermas generadas por vencimiento o deterioro.

El instrumento asociado es la ficha de observación, estructurada con indicadores específicos que permitan registrar de manera sistemática: (a) el flujo de entrada y salida de materias primas perecederas; (b) los criterios empíricos utilizados por el personal para la toma de decisiones de compra; (c)

la frecuencia, magnitud y causas de las mermas identificadas; y (d) las condiciones físicas de almacenamiento de los insumos sujetos a deterioro. La aplicación de esta técnica permitirá contrastar la información verbal obtenida mediante las entrevistas con la realidad operativa observada directamente.

3.5.2 Entrevista Semiestructurada

La entrevista semiestructurada constituye una técnica de diálogo planificado entre el investigador y el sujeto informante, orientada a obtener información cualitativa de carácter profundo sobre el objeto de estudio (Hurtado, 2010). A diferencia de la entrevista estructurada, este formato combina preguntas predefinidas con la flexibilidad de incorporar interrogantes emergentes durante el diálogo, lo que permite explorar con mayor detalle aquellos aspectos de especial relevancia que surjan espontáneamente en la conversación.

Las entrevistas serán aplicadas a los tres informantes claves identificados en la muestra: la gerente general, la encargada de almacén y el responsable de producción de la Pastelería Casserissima. El instrumento utilizado es la guía de entrevista, compuesta por preguntas abiertas y semidirigidas organizadas en torno a cuatro ejes temáticos: (a) descripción de los procesos actuales de planificación de compras; (b) percepción sobre las principales causas de desabastecimiento y mermas; (c) identificación de los picos de demanda y su estacionalidad a lo largo del año; y (d) expectativas funcionales del personal frente a un sistema predictivo automatizado. Las entrevistas serán grabadas previo consentimiento de los informantes y transcritas para su posterior análisis cualitativo.

3.5.3 Revisión Documental

La revisión documental es una técnica que permite obtener datos secundarios a partir del análisis sistemático de registros, archivos e informes existentes en la organización o en fuentes bibliográficas especializadas (Arias, 2012). Esta técnica resulta indispensable cuando el investigador necesita acceder a información histórica que no puede ser generada experimentalmente. En esta investigación, la revisión documental se concentra en el análisis de los registros históricos de ventas diarias y la gestión de inventarios almacenados en hojas de cálculo de Microsoft Excel por la Pastelería Casserissima, los cuales constituyen la fuente de datos cuantitativos que alimentará el proceso de entrenamiento del modelo de aprendizaje automático.

El instrumento correspondiente es la matriz de recolección de datos cuantitativos, diseñada para registrar de manera estructurada las siguientes variables: fecha de registro, código y nombre del producto, cantidad vendida por día, cantidad de insumos recibida, cantidad de merma reportada y precio unitario de cada insumo. Esta matriz facilitará las fases posteriores de preprocesamiento, limpieza y normalización del dataset que servirá como insumo principal para el algoritmo de Random Forest.

3.6 TÉCNICAS E INSTRUMENTOS DE ANÁLISIS DE DATOS

El procesamiento y análisis de los datos recolectados se llevará a cabo mediante un conjunto de técnicas computacionales especializadas, estructuradas en fases secuenciales que garantizan la rigurosidad estadística del modelo predictivo. Tal como señalan Hernández et al. (2014), el análisis

de datos implica seleccionar y aplicar las herramientas estadísticas adecuadas en función de la naturaleza de los datos, los objetivos de la investigación y las características del modelo propuesto. Todas las técnicas descritas a continuación se implementarán utilizando el lenguaje de programación Python, que ofrece un ecosistema maduro de bibliotecas de código abierto especialmente adecuadas para el análisis de series temporales y el aprendizaje automático.

3.6.1 Análisis Exploratorio de Datos (EDA)

El análisis exploratorio de datos (EDA, por sus siglas en inglés) constituye la primera etapa del procesamiento analítico y tiene como propósito comprender la estructura interna, la distribución estadística y las relaciones entre las variables del dataset histórico antes de proceder al modelado predictivo. Esta etapa incluye la detección y el tratamiento de valores atípicos (outliers) mediante diagramas de caja y bigotes, el manejo de datos faltantes a través de técnicas de imputación, la verificación de la distribución de la demanda por producto y período, y el análisis de la autocorrelación de la serie temporal para identificar patrones de estacionalidad.

Las herramientas computacionales empleadas en esta fase son: la biblioteca panda para la manipulación y limpieza de datos tabulares; numpy para el procesamiento numérico vectorizado; y matplotlib junto con seaborn para la generación de gráficos estadísticos descriptivos que permitan visualizar los patrones de demanda, la distribución de las mermas y las tendencias estacionales del negocio repostero.

3.6.2 Ingeniería de Características (Feature Engineering)

La ingeniería de características consiste en la transformación y creación de variables derivadas a partir de los datos originales, con el propósito de enriquecer la capacidad representativa y predictiva del modelo. Dado que el algoritmo de Random Forest no posee mecanismos nativos para capturar la autocorrelación temporal de las series, esta etapa adquiere un papel determinante en la calidad de las predicciones. Para esta investigación, se generarán las siguientes categorías de variables adicionales: variables de calendario (día de la semana, semana del mes, mes del año, indicador de día festivo o fin de semana), variables rezagadas o lag features que capturen los valores de demanda de los períodos inmediatamente anteriores, y medias móviles de ventanas de 7 y 14 días que suavicen las fluctuaciones aleatorias de corto plazo.

Esta construcción sistemática de características permite al modelo identificar correctamente los patrones de estacionalidad semanal y mensual propios del negocio de repostería artesanal, tales como el incremento de la demanda en fechas especiales (Navidad, Carnaval, Semana Santa, Día de las Madres) o los picos de consumo de fin de semana que caracterizan a la Pastelería Casserissima.

3.6.3 Entrenamiento y Validación del Modelo Random Forest

El entrenamiento del modelo predictivo se realizará utilizando la clase RandomForestRegressor de la biblioteca scikit-learn de Python. El proceso de entrenamiento se apoyará en la técnica de validación cruzada k-fold con $k = 5$, que divide el conjunto de datos en cinco subconjuntos mutuamente excluyentes y evalúa el modelo en cada posible combinación de particiones

de entrenamiento y prueba. Este procedimiento garantiza que las métricas de desempeño sean estadísticamente representativas y no dependientes de una única partición aleatoria, reduciendo el riesgo de sobreajuste del modelo.

La optimización de los hiperparámetros del modelo —incluyendo el número de árboles estimadores (`n_estimators`), la profundidad máxima de cada árbol (`max_depth`), el número mínimo de muestras para dividir un nodo (`min_samples_split`) y el número de características consideradas en cada división (`max_features`)— se realizará mediante la técnica de búsqueda sistemática en cuadrícula (Grid Search con validación cruzada), que evaluará exhaustivamente todas las combinaciones posibles de valores predefinidos para cada hiperparámetro e identificará la configuración que minimice el error de predicción sobre los datos de validación.

3.6.4 Evaluación Mediante Métricas Estadísticas: MAPE y RMSE

El desempeño del modelo predictivo será cuantificado de manera rigurosa mediante dos indicadores estadísticos complementarios. Por un lado, el Error Cuadrático Medio de la Raíz (RMSE, Root Mean Square Error) mide la magnitud promedio de los errores de predicción en las mismas unidades de la variable dependiente, penalizando con mayor peso las desviaciones grandes que podrían traducirse en desabastecimiento crítico o acumulación excesiva de inventario perecedero. Su fórmula se expresa como la raíz cuadrada de la media de los errores cuadráticos: $RMSE = \sqrt{[(1/n) \sum (y_i - \hat{y}_i)^2]}$.

Por otro lado, el Error Porcentual Absoluto Medio (MAPE, Mean Absolute Percentage Error) ofrece una perspectiva relativa del desempeño del modelo al expresar el error promedio como porcentaje de la demanda real observada, lo que facilita la comparación del rendimiento entre productos de distinto

volumen de ventas y permite interpretar la precisión del pronóstico en términos intuitivos para la gerencia. Su fórmula es: $MAPE = (1/n) \sum |(y_i - \hat{y}_i) / y_i| \times 100$.

La integración dinámica de ambas métricas en el sistema permitirá calcular y actualizar de manera continua el inventario de seguridad y el Punto de Reorden Evolutivo, adaptando automáticamente las recomendaciones de compra a la precisión histórica más reciente del modelo. De este modo, el sistema exhibe un comportamiento de aprendizaje continuo que lo diferencia de los métodos de inventario estático tradicionales.

3.6.5 Validación Retrospectiva mediante Backtesting (Walk-Forward Validation)

La eficacia global del sistema predictivo será evaluada mediante la técnica de backtesting con ventana deslizante —conocida en la literatura especializada como *walk-forward validation*—, que consiste en simular de manera retrospectiva el comportamiento del modelo sobre períodos históricos reales ya ocurridos. A diferencia de la validación cruzada estándar, esta técnica respeta la naturaleza temporal de los datos al garantizar que los datos de prueba sean siempre posteriores en el tiempo a los datos de entrenamiento, evitando así la fuga de información futura hacia el proceso de entrenamiento.

El procedimiento consiste en entrenar el modelo sobre una ventana inicial de datos históricos, generar predicciones para el período inmediatamente siguiente, calcular las métricas de error MAPE y RMSE sobre dichas predicciones, avanzar la ventana temporal en un período y repetir el proceso de manera iterativa hasta cubrir la totalidad del horizonte histórico disponible. Los resultados acumulados permitirán cuantificar, con evidencia empírica, la reducción porcentual de mermas y el nivel de mejora en la optimización del

inventario que habría generado el sistema si hubiese estado operativo durante el período analizado.

3.7 DISEÑO OPERATIVO

El diseño operativo organiza de manera sistemática las fases de ejecución de la investigación, estableciendo la correspondencia explícita entre cada objetivo específico y las actividades, técnicas, instrumentos y resultados esperados que guiarán el desarrollo del sistema predictivo propuesto. En concordancia con la naturaleza proyectiva del estudio y con los postulados de Hurtado (2010) respecto a la planificación metodológica de las investigaciones de desarrollo tecnológico, el diseño operativo se estructura en cuatro fases secuenciales e interdependientes, cuya lógica de progresión refleja el avance sistemático desde el diagnóstico situacional hasta la validación cuantitativa del modelo. Las fases se describen a continuación y se sintetizan en el cuadro 1.

Cuadro 1. Diseño Operativo de la Investigación

Objetivo Específico	Fase	Actividades	Técnicas / Instrumentos	Resultado Esperado
Diagnosticar los flujos de inventario y patrones de demanda actuales en la Pastelería Casserissima, para el establecimiento	I. Diagnóstico	Observación directa del proceso de inventarios. Entrevistas al personal clave. Revisión y depuración del registro histórico de ventas en Excel. Identificación de	Observación participante. Entrevista semiestructurada. Revisión documental. Ficha de observación. Matriz de recolección de datos.	Diagnóstico situacional documentado. Dataset depurado y estructurado.

Objetivo Específico	Fase	Actividades	Técnicas / Instrumentos	Resultado Esperado
de los requerimientos lógicos necesarios en la automatización de los planes de compra.		variables relevantes para el modelo.		
Entrenar el algoritmo de aprendizaje automático (Random Forest) para la captura de la estacionalidad de la demanda de productos perecederos, garantizando la precisión en la identificación de patrones de consumo.	II. Modelado	Preprocesamiento y normalización del dataset. Ingeniería de características (lag features, medias móviles, variables estacionales). Entrenamiento del modelo. Ajuste de hiperparámetros mediante Grid Search.	Python (scikit-learn, pandas, numpy). Validación cruzada k-fold (k=5). Curvas de aprendizaje. Grid Search.	Modelo Random Forest entrenado, optimizado y validado estadísticamente.

Objetivo Específico	Fase	Actividades	Técnicas / Instrumentos	Resultado Esperado
Elaborar el tablero de control gerencial e Interfaz de usuario que integre un Punto de Reorden Evolutivo, facilitando el aprendizaje continuo del error de pronóstico con base en métricas estadísticas (MAPE/RMSE).	III. Desarrollo	Cálculo del Punto de Reorden Evolutivo. Diseño de la interfaz gráfica del dashboard. Integración del motor predictivo. Generación de alertas automáticas de reorden por producto.	Python (Streamlit / Dash). Visualización con Plotly. Fórmulas de inventario de seguridad dinámico basadas en MAPE/RMSE.	Dashboard funcional con Punto de Reorden Evolutivo integrado y alertas automáticas.
Validar la eficacia del sistema mediante una prueba retrospectiva (Backtesting), para la cuantificación	IV. Validación	Backtesting con ventana deslizante sobre datos históricos. Cálculo de MAPE y RMSE por período. Comparación del inventario	Walk-forward validation. Métricas MAPE y RMSE. Análisis comparativo simulado. Python (pandas, matplotlib).	Informe de validación con reducción cuantificada de mermas y mejora del nivel de servicio.

Objetivo Específico	Fase	Actividades	Técnicas / Instrumentos	Resultado Esperado
de la disminución potencial de mermas y la optimización de los niveles de inventario en la organización.		predicho vs. inventario real. Cuantificación porcentual de mermas evitadas.		

Fuente: Elaboración propia (2026).

3.7.1 Fase I: Diagnóstico

La primera fase comprende el levantamiento integral de información primaria en las instalaciones de la Pastelería Casserissima. Mediante la observación directa y las entrevistas semiestructuradas aplicadas a los tres informantes clave, se identificarán con precisión las deficiencias actuales en el control de inventarios, los criterios empíricos que rigen las decisiones de compra y las variables operativas que inciden en la volatilidad de la demanda. Paralelamente, la revisión documental permitirá extraer, estructurar y depurar el conjunto de datos históricos de ventas almacenados en Excel, que servirá como insumo cuantitativo principal para las fases subsiguientes. El producto entregable de esta fase es el diagnóstico situacional documentado y el dataset limpio, estructurado y listo para su procesamiento analítico.

3.7.2 Fase II: Modelado

En la segunda fase se ejecuta el proceso central de construcción del motor predictivo. Los datos históricos depurados serán sometidos al análisis exploratorio descrito en la sección 3.6.1, seguido de la ingeniería de características detallada en la sección 3.6.2, que generará el conjunto de variables predictoras capaz de capturar la estacionalidad de la demanda repostera. Sobre este dataset enriquecido, se entrenará el modelo Random Forest, se optimizarán sus hiperparámetros mediante Grid Search con validación cruzada k-fold y se evaluará su precisión a través de las métricas MAPE y RMSE. El entregable de esta fase es un motor predictivo estadísticamente validado, documentado y optimizado para el contexto específico de la Pastelería Casserissima.

3.7.3 Fase III: Desarrollo

La tercera fase está orientada al diseño y la construcción del tablero de control gerencial que materializa la propuesta tecnológica. A partir de las predicciones generadas por el modelo entrenado, se calculará el Punto de Reorden Evolutivo mediante una fórmula que incorpora dinámicamente el stock de seguridad ajustado en función del MAPE y el RMSE del período de evaluación más reciente, garantizando así que el sistema se adapte de manera continua a los cambios en el comportamiento de la demanda. Este mecanismo de ajuste automático será integrado en una interfaz de usuario desarrollada en Python mediante el framework Streamlit o Dash, que presentará de forma visual, clara y comprensible los pronósticos de demanda, los niveles de inventario recomendados y las alertas automáticas de reposición para cada insumo perecedero administrado por la pastelería.

3.7.4 Fase IV: Validación

La cuarta y última fase corresponde a la evaluación empírica de la eficacia del sistema completo mediante el backtesting con ventana deslizante descrito en la sección 3.6.5. Se simulará el comportamiento del sistema sobre el período histórico disponible, comparando los inventarios predichos y las decisiones de compra recomendadas por el modelo con los registros reales de compras y mermas efectivamente ocurridos en la Pastelería Casserissima. Los resultados se expresarán en términos cuantitativos: reducción porcentual potencial de mermas de insumos perecederos, mejora en el nivel de servicio al consumidor final y disminución de los episodios de desabastecimiento crítico. El informe de validación resultante constituirá la evidencia técnica que sustentará las conclusiones, las recomendaciones y la demostración de la factibilidad operativa del sistema propuesto.

Referencias

- Afanador Jiménez, M., Campo Maichel, I., Casadiegos Chaparro, S. J., & Casallas Estrella, J. S. (2021). Diseño de un modelo de pronóstico de demanda basado en Machine Learning y un modelo multi-objetivo para planeación de la producción en una industria panificadora [Trabajo de Grado, Pontificia Universidad Javeriana]. Repositorio Institucional Javeriana.
<https://apidspace.javeriana.edu.co/server/api/core/bitstreams/0eddefa4-7ffe-4d98-b511-13cf4d079fca/content>
- Alpaydin, E. (2020). Introduction to machine learning (4.^a ed.). MIT Press.
- Arias, F. G. (2012). El proyecto de investigación: Introducción a la metodología científica (6.^a ed.). Editorial Episteme.
- Asamblea Nacional Constituyente. (1999). Constitución de la República Bolivariana de Venezuela. Gaceta Oficial N° 36.860, 30 de diciembre de 1999.
- Asamblea Nacional de la República Bolivariana de Venezuela. (2001). Ley Especial Contra los Delitos Informáticos. Gaceta Oficial N° 37.313, 30 de octubre de 2001.
- Asamblea Nacional de la República Bolivariana de Venezuela. (2002). Ley Orgánica del Sistema Venezolano para la Calidad. Gaceta Oficial Extraordinaria N° 37.543, 23 de octubre de 2002.
- Asamblea Nacional de la República Bolivariana de Venezuela. (2008). Ley Orgánica de Seguridad y Soberanía Agroalimentaria. Gaceta Oficial Extraordinaria N° 5.889, 31 de julio de 2008.
- Ballou, R. H. (2004). Logística: Administración de la cadena de suministro (5.^a ed.). Pearson Educación.

- Biau, G., & Scornet, E. (2016). A random forest guided tour. *Test*, 25(2), 197–227. <https://doi.org/10.1007/s11749-016-0481-7>
- Bowersox, D. J., Closs, D. J., & Cooper, M. B. (2013). *Supply chain logistics management* (4.^a ed.). McGraw-Hill.
- Box, G. E. P., Jenkins, G. M., & Reinsel, G. C. (2015). *Time series analysis: Forecasting and control* (5.^a ed.). John Wiley & Sons.
- Brassard, G., & Bratley, P. (1997). *Fundamentos de algoritmia*. Prentice Hall.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Cachon, G., & Terwiesch, C. (2013). *Matching supply with demand: An introduction to operations management* (3.^a ed.). McGraw-Hill.
- Chai, T., & Draxler, R. R. (2014). Root mean square error (RMSE) or mean absolute error (MAE)? – Arguments against avoiding RMSE in the literature. *Geoscientific Model Development*, 7(3), 1247-1250. <https://doi.org/10.5194/gmd-7-1247-2014>
- Chopra, S., & Meindl, P. (2016). *Supply chain management: Strategy, planning, and operation* (6.^a ed.). Pearson.
- Consejo Nacional del Comercio y los Servicios [Consecomercio]. (2023). *Impacto de la volatilidad en la cadena de suministro y la adopción tecnológica en Venezuela*. Consecomercio.
- Davis, B., Lockwood, A., Pantelidis, I., & Alcott, P. (2018). *Food and beverage management* (6.^a ed.). Routledge.
- Dopson, L. R., & Hayes, D. K. (2015). *Food and beverage cost control* (6.^a ed.). John Wiley & Sons.
- Eckerson, W. W. (2010). *Performance dashboards: Measuring, monitoring, and managing your business* (2.^a ed.). John Wiley & Sons.
- Few, S. (2006). *Information dashboard design: The effective visual communication of data*. O'Reilly Media.
- Gisslen, W. (2017). *Professional baking* (7.^a ed.). John Wiley & Sons.

- Hastie, T., Tibshirani, R., & Friedman, J. (2009). The elements of statistical learning: Data mining, inference, and prediction (2.^a ed.). Springer.
- Heizer, J., & Render, B. (2014). Operations management: Sustainability and supply chain management (11.^a ed.). Pearson.
- Hillier, F. S., & Lieberman, G. J. (2010). Introducción a la investigación de operaciones (9.^a ed.). McGraw-Hill.
- Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679-688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>
- Krajewski, L. J., Ritzman, L. P., & Malhotra, M. K. (2013). Operations management: Processes and supply chains (10.^a ed.). Pearson.
- Lira Pacheco, A. M., & Tinoco Ricapa, N. L. (2025). Sistema basado en Machine Learning para predicción de inventarios para una empresa del sector industrial [Trabajo de Suficiencia Profesional, Universidad Peruana de Ciencias Aplicadas]. Repositorio Académico UPC. <http://hdl.handle.net/10757/687929>
- Mitchell, T. M. (1997). Machine learning. McGraw-Hill.
- Montes Meneses, L. S., & Rivas Higuereis, A. A. (2022). Plan de mejora para la calidad aplicado al proceso productivo de la panadería y pastelería D'Ivanna, en Maturín-Estado Monagas [Trabajo de Grado, Universidad de Oriente]. Repositorio Institucional de la Universidad de Oriente.
- Nahmias, S. (2011). Production and operations analysis (6.^a ed.). McGraw-Hill.
- Organización de las Naciones Unidas para la Alimentación y la Agricultura [FAO]. (2023). El estado mundial de la agricultura y la alimentación 2023. FAO. <https://doi.org/10.4060/cc7724es>
- Parfitt, J., Barthel, M., & Macnaughton, S. (2010). Food waste within food supply chains: Quantification and potential for change to 2050. *Philosophical Transactions of the Royal Society B: Biological Sciences*, 365(1554), 3065-3081. <https://doi.org/10.1098/rstb.2010.0126>

- Parmenter, D. (2015). Key performance indicators: Developing, implementing, and using winning KPIs (3.^a ed.). John Wiley & Sons.
- Provost, F., & Fawcett, T. (2013). Data science for business: What you need to know about data mining and data-analytic thinking. O'Reilly Media.
- Riggs, J. L. (2005). Sistemas de producción: Planeación, análisis y control (3.^a ed.). Limusa Wiley.
- Romero, R. (2021). Minería de datos y aprendizaje automático para la toma de decisiones empresariales. Alfaomega.
- Shmueli, G., & Koppius, O. R. (2011). Predictive analytics in information systems research. *MIS Quarterly*, 35(3), 553–572.
- Siegel, E. (2013). Predictive analytics: The power to predict who will click, buy, lie, or die. John Wiley & Sons.
- Silver, E. A., Pyke, D. F., & Peterson, R. (1998). Inventory management and production planning and scheduling (3.^a ed.). John Wiley & Sons.
- Silver, E. A., Pyke, D. F., & Thomas, D. J. (2016). Inventory and production management in supply chains (4.^a ed.). CRC Press.