



UNIVERSIDAD DE ORIENTE

NUCLEO DE MONAGAS

ESCUELA DE INGENIERIA Y CIENCIAS APLICADAS

DEPARTAMENTO DE INGENIERIA DE SISTEMAS

CONTROL DE LOS SISTEMAS DE PRODUCCIÓN

ADMINISTRACIÓN DE INVENTARIOS

PROFESOR:

JUAN OLIVEIRA

BACHILLERES:

JORFRAN GIL

C.I 26.933.738

YEFFERSON HERNANDEZ

C.I 29.936.033

MATURIN, MAYO 2026

INDICE

INTRODUCCION	1
PLANTEAMIENTO DEL PROBLEMA	2
FASE I: DIAGNÓSTICO Y RECOLECCIÓN DE DATOS REAL	4
1.1 Trabajo de Campo	4
1.2 Análisis de la Causa Raíz	4
FASE II: MODELADO PREDICTIVO (TÉCNICA MONTE CARLO)	5
2.1 Definición de Variables Estocásticas y Justificación Técnica	5
2.2 Ejecución de la Simulación Computacional en Python	6
2.3 Cuantificación del Riesgo y Evaluación de Unidades Críticas	6
FASE III: DISEÑO DE SOLUCIÓN SMART SUPPLY CHAIN (TO-BE)	10
3.1 Arquitectura Blockchain y Smart Contracts	10
3.2 Lote Económico Dinámico	13
FASE IV: OPTIMIZACIÓN Y MACHINE LEARNING	14
4.1 Punto de Reorden Evolutivo	14
4.2 Almacenamiento Inteligente (Optimización de Layout)	15
CONCLUSIÓN	16
REFERENCIAS BIBLIOGRAFICAS	17
ANEXOS	18

INTRODUCCION

La gestión de inventarios perecederos en la industria alimentaria constituye un desafío logístico de alta complejidad, condicionado por la volatilidad estocástica de la demanda y la incertidumbre en los tiempos de reabastecimiento. En economías con fluctuaciones operativas severas, la dependencia de modelos de planificación empíricos o sistemas estáticos desencadena ineficiencias críticas que vulneran la rentabilidad organizacional. Bajo este contexto, la pastelería Casseríssima, ubicada en la ciudad de Maturín, enfrenta un escenario de riesgo logístico constante caracterizado por la interrupción de sus líneas de producción y la pérdida financiera derivada de la caducidad de insumos de alta criticidad, tales como lácteos y cartones de huevo. La ausencia de integración tecnológica en su cadena de suministro fomenta el denominado efecto látigo, distorsionando la información de consumo y forzando la acumulación innecesaria de inventario de seguridad.

Para mitigar esta vulnerabilidad estructural, la presente investigación expone el diseño de una arquitectura tecnológica integral orientada a la automatización del aprovisionamiento. El estudio transita desde un diagnóstico operativo de campo hasta la formulación de un ecosistema predictivo sustentado en algoritmos de Machine Learning y herramientas de simulación computacional de Monte Carlo. Asimismo, la propuesta despliega una solución descentralizada mediante contratos inteligentes (Smart Contracts) y telemetría de la Internet de las Cosas (IoT), convergiendo con técnicas de optimización espacial para el rediseño del almacenamiento físico. La articulación de estas disciplinas ingenieriles persigue la erradicación de los sesgos humanos en las decisiones de compra, garantizando un flujo ininterrumpido de materia prima que asegure la viabilidad comercial y operativa de la organización.

PLANTEAMIENTO DEL PROBLEMA

La gestión eficiente de inventarios en la industria alimentaria constituye un pilar logístico ineludible para garantizar la viabilidad operativa, particularmente frente al reto que supone la administración de bienes de alta perecibilidad. La dinámica contemporánea de las cadenas de suministro exige una sincronización matemática precisa entre el flujo de abastecimiento y la demanda real para salvaguardar la rentabilidad organizacional. Esta rigurosidad técnica se agudiza en entornos económicos caracterizados por una profunda volatilidad y fluctuaciones constantes en la disponibilidad de materias primas. Bajo tales condiciones de inestabilidad, la dependencia de esquemas de planificación estáticos vulnera la capacidad de respuesta de las empresas, lo cual fuerza la transición obligatoria hacia infraestructuras tecnológicas que mitiguen la descapitalización por mermas y aseguren la continuidad del ciclo productivo.

Dentro de este ecosistema comercial, la pastelería Casseríssima, localizada en la ciudad de Maturín, experimenta vulnerabilidades críticas en el control de sus insumos fundamentales. La operatividad diaria de la organización refleja un comportamiento marcadamente estocástico, donde los requerimientos de ingredientes esenciales, tales como lácteos y cartones de huevo, oscilan de forma impredecible entre 3 y 12 unidades diarias.

A esta variación interna se superpone la inestabilidad de la logística externa, evidenciada por tiempos de entrega de los proveedores que fluctúan erráticamente entre 2 y 11 días. Actualmente, el registro y la emisión de órdenes de compra se ejecutan de manera rudimentaria mediante conteos visuales y hojas de cálculo desvinculadas de la realidad del mercado. Esta configuración empírica suprime la visibilidad técnica del almacén e imposibilita la anticipación de escenarios de escasez.

La desconexión digital con los distribuidores mayoristas y la toma de decisiones fundamentada en la intuición del personal desencadenan un efecto látigo severo que desestabiliza las finanzas de la empresa. Ante la amenaza del desabastecimiento, la gerencia emite órdenes de compra sobredimensionadas que

saturan la capacidad de almacenamiento y ocasionan cuantiosas mermas por la caducidad ineludible de los alimentos orgánicos. Simultáneamente, la convergencia de picos de consumo con demoras en el transporte provoca el colapso del inventario de seguridad. La perpetuación de esta dinámica somete a la empresa a un desgaste financiero insostenible, materializado en pérdidas mensuales equivalentes al 12 % de la operatividad y una probabilidad matemática de quiebre de stock del 32.10 %. Esta fractura estructural demuestra la urgencia de erradicar los enfoques de reposición tradicionales e implementar una arquitectura algorítmica capaz de procesar el caos operativo.

La comprobación empírica de las deficiencias logísticas y el riesgo inminente de paralización productiva exigen una intervención fundamentada en las ciencias computacionales para suprimir la intermediación humana en el cálculo de compras. Sobre la base de la fenomenología descrita, la presente investigación orienta su desarrollo hacia la resolución de la inestabilidad del flujo de materiales mediante el planteamiento de la siguiente interrogante científica: ¿Cómo desarrollar un sistema de analítica predictiva fundamentado en Machine Learning y tecnología descentralizada que optimice la gestión de inventarios perecederos en la pastelería Casseríssima?

FASE I: DIAGNÓSTICO Y RECOLECCIÓN DE DATOS REAL

1.1 Trabajo de Campo

El análisis operativo en la panadería Casseríssima toma como unidad de estudio la línea de pastelería de vitrina, un segmento comercial crítico cuya alta susceptibilidad a la degradación física exige un control riguroso de sus insumos correspondientes. La recopilación de los datos históricos revela un comportamiento marcadamente estocástico en la demanda diaria. Los registros demuestran que el requerimiento mínimo se ubica en 3 unidades diarias, mientras que los picos máximos alcanzan las 12 unidades, lo cual arroja una salida promedio de 6.5 unidades por día. Esta alta variabilidad imposibilita la aplicación de métodos de planificación empíricos, puesto que la dispersión entre los límites operativos fractura cualquier intento de parametrización estática y expone al sistema a un riesgo inminente de desabastecimiento.

A la fluctuación del consumo interno se suma la inestabilidad en la cadena de suministro externa. La evaluación de las órdenes de compra emitidas durante los últimos seis meses evidencia que los tiempos de entrega de los proveedores de materia prima (*Lead Time*) oscilan de forma errática entre 2 y 11 días. La colisión de esta incertidumbre logística con la volatilidad de la demanda diaria anula la eficacia de las políticas de inventario tradicionales (Silver, Pyke y Thomas, 2017). Cuando el sistema experimenta un requerimiento máximo sostenido que coincide con un tiempo de entrega prolongado, la reserva de seguridad colapsa de manera inevitable.

1.2 Análisis de la Causa Raíz

El diagnóstico profundo de esta dinámica operativa revela que la causa raíz del caos logístico reside en la absoluta falta de conexión digital en tiempo real con la base de datos de los proveedores de materia prima. La empresa ejecuta sus pedidos de forma manual sobre la base de aproximaciones empíricas, una práctica que suprime la visibilidad técnica de la cadena de suministro.

Esta desconexión tecnológica desencadena el denominado "Efecto Látigo" o *Bullwhip Effect*, un fenómeno logístico donde la información de la demanda real se distorsiona drásticamente conforme asciende hacia el proveedor (Chase y Jacobs, 2014). Ante la amenaza de un quiebre de stock, el personal formula órdenes de compra sobredimensionadas como mecanismo de defensa, una reacción que inyecta un exceso de inventario en los almacenes. Posteriormente, la acumulación de estos insumos perecederos ocasiona severas mermas por caducidad, un escenario que consolida un ciclo reactivo que oscila sistemáticamente entre el sobre-stock perjudicial y la ruptura de inventario (Mweshi, 2022).

FASE II: MODELADO PREDICTIVO (TÉCNICA MONTE CARLO)

2.1 Definición de Variables Estocásticas y Justificación Técnica

La evaluación metodológica exige abandonar el determinismo para capturar la verdadera volatilidad del sistema. La selección de las variables estocásticas recae estrictamente sobre la demanda diaria y el tiempo de entrega del proveedor (Lead Time). La adopción de la demanda como variable probabilística se justifica por la naturaleza oscilatoria de la producción pastelera, donde el requerimiento de insumos fluctúa drásticamente entre 3 y 12 cartones de huevo diarios. Por su parte, la inestabilidad del transporte logístico local y las deficiencias en la cadena de suministro obligan a modelar el Lead Time como una segunda variable aleatoria, puesto que las entregas varían de forma errática entre 2 y 11 días. El uso de promedios estáticos para estas métricas en el modelo clásico del EOQ ocultaría la varianza extrema en las colas de la distribución estadística. Esta parametrización estocástica corrige dicha ceguera al someter el sistema a escenarios de estrés realista, como la coincidencia de un pico de producción con un retraso severo del distribuidor avícola.

2.2 Ejecución de la Simulación Computacional en Python

El procesamiento de esta matriz de incertidumbre requirió la construcción de un motor predictivo basado en la Simulación Monte Carlo mediante el lenguaje de programación Python. El algoritmo informático se configuró para ejecutar exactamente 1000 iteraciones del ciclo de reabastecimiento. La arquitectura del código incorpora librerías de análisis numérico computacional, específicamente NumPy para la generación de vectores pseudoaleatorios y pandas para la tabulación de los miles de escenarios resultantes. Durante cada iteración, el sistema extrae un valor aleatorio para el tiempo de entrega y acumula la demanda diaria simulada a lo largo de dicho lapso de espera. Esta carga computacional somete la política empírica de compras a un espectro exhaustivo de realidades operativas combinadas, lo cual supera por completo las restricciones analíticas de las herramientas ofimáticas convencionales y garantiza la reproducibilidad matemática de la investigación.

2.3 Cuantificación del Riesgo y Evaluación de Unidades Críticas

La métrica de evaluación se establece en unidades físicas enteras, definidas en este contexto operativo como cartones de huevo. El escrutinio de los resultados arrojados por las 1000 iteraciones sobre el punto de reorden empírico actual (el cual obliga a comprar cuando el inventario desciende a 40 cartones) arroja una probabilidad exacta de quiebre de stock del **32.10%**. Esta cifra demuestra matemáticamente que la pastelería agotará sus existencias antes de recibir el suministro en más de tres de cada diez ciclos de compra, lo cual paraliza las líneas de horneado y genera pérdidas irre recuperables. Como evidencia diagnóstica, el script de Python generó un histograma de frecuencias relativas que ilustra visualmente la alta concentración de escenarios donde la demanda acumulada perfora la barrera del inventario de seguridad durante el tiempo de espera. La confirmación matemática de esta vulnerabilidad estructural justifica un modelo de Machine Learning para erradicar la toma de decisiones basada en la intuición humana.




Figura 1. Análisis de sensibilidad

Nota. La curva representa la variación de la probabilidad de quiebre de stock en función del Punto de Reorden evaluado, obtenida tras 10.000 iteraciones Monte Carlo con distribuciones triangulares para la demanda diaria (mín. 3, moda 6, máx. 12 cartones) y el tiempo de entrega (mín. 2, moda 5, máx. 11 días). La línea roja discontinua señala el ROP empírico actual de la pastelería Casseríssima (40 unidades), el cual arroja una probabilidad de quiebre del 32.10%. La franja verde demarca la zona de riesgo operativo aceptable, inferior al 10%, alcanzable a partir de un ROP de 55 unidades. Elaboración propia.




Figura 2. Simulación estocástica de la demanda de cartones de huevo durante el tiempo de entrega logístico

Nota. La franja coloreada en rojo ilustra la zona de riesgo operativo, la cual agrupa el 32.10% de los escenarios simulados donde el consumo supera el umbral de las 40 unidades antes de recibir el reabastecimiento. Elaboración propia sobre la base de los datos diagnosticados en la Fase I y procesados mediante el motor predictivo en Python.

La evidencia visual expuesta en la figura precedente ratifica la insostenibilidad matemática de las operaciones actuales. La zona demarcada en el histograma agrupa el 32.10% de los escenarios simulados, lo cual representa la fracción exacta de los ciclos de reabastecimiento que culminan inevitablemente en un desabastecimiento físico de cartones de huevo. Esta vulnerabilidad comprobada corrobora que la empresa asume un nivel de riesgo logístico incompatible con la rentabilidad operativa sostenida. El mantenimiento de una política empírica de compras frente a un entorno de altísima varianza estocástica condena a la organización a sufrir interrupciones recurrentes en la línea de producción y mermas por ventas perdidas. Por consiguiente, la erradicación de este margen de falla logística exige el abandono definitivo de los modelos tradicionales y la

implementación de una arquitectura predictiva superior. La integración de modelos de Machine Learning que blindará la cadena de suministro de la pastelería.




Figura 3 Grafica de nivel de inventario vs tiempo

Nota. La figura superior ilustra el comportamiento del inventario de cartones de huevo bajo la política empírica actual (ROP = 40 unidades), donde se evidencian los episodios de quiebre de stock producidos por la coincidencia entre picos de demanda y retrasos logísticos. La figura inferior expone el desempeño de la política óptima propuesta (ROP = 55 unidades), la cual elimina los quiebres al ampliar el umbral de seguridad en concordancia con los resultados del análisis de sensibilidad Monte Carlo. Las líneas punteadas verticales en color morado indican cada emisión autónoma de orden de compra. Elaboración propia mediante simulación estocástica en Python sobre la base de los datos diagnosticados en la Fase I.

FASE III: DISEÑO DE SOLUCIÓN SMART SUPPLY CHAIN (TO-BE)

3.1 Arquitectura Blockchain y Smart Contracts

La arquitectura TO-BE propuesta para la pastelería Casseríssima se fundamenta en la automatización descentralizada para erradicar las severas ineficiencias del reabastecimiento reactivo. La integración de contratos inteligentes permite que las reglas de negocio logísticas se ejecuten de forma determinista y sin necesidad de intermediación humana. La adopción de esta tecnología de registro distribuido sustituye la vulnerabilidad de las decisiones empíricas por protocolos informáticos inalterables. Esta supresión de los sesgos cognitivos y de la manipulación manual de los volúmenes de compra elimina estructuralmente la propagación del efecto látigo a lo largo de la cadena de suministro (Kshetri, 2018).

Dado que los contratos inteligentes operan en entornos lógicos aislados y carecen de percepción sobre el mundo material, la viabilidad de la arquitectura exige la implementación de oráculos informáticos. En el ecosistema productivo de Casseríssima, estos oráculos se materializan mediante la convergencia con dispositivos de la Internet de las Cosas (IoT), específicamente a través de básculas de peso ancladas a los depósitos de harina o azúcar y sensores RFID desplegados en los refrigeradores. Esta infraestructura sensorial captura las fluctuaciones reales del inventario físico y transmite la telemetría hacia la red blockchain para alimentar el estado del contrato (Christidis & Devetsikiotis, 2016). El sistema transaccional obedece a un disparador digital programado con estricta rigurosidad. La orden de compra autónoma hacia el distribuidor mayorista se emite en el instante exacto en que la lectura del oráculo registra un volumen de existencias por debajo del punto de reorden dinámico, un umbral de seguridad definido matemáticamente durante las simulaciones estocásticas previas.

El cierre del ciclo de abastecimiento demuestra la solidez de la vinculación entre el movimiento físico de las cargas y la ejecución financiera algorítmica. La recepción de los insumos en las instalaciones de la pastelería desencadena la validación digital del lote, una acción que inscribe un bloque de información definitivo

en el libro mayor inmutable de la blockchain. Esta técnica de almacenamiento descentralizado garantiza la trazabilidad absoluta de la materia prima perecedera y blindo el historial logístico contra alteraciones deliberadas (Saberí et al., 2019). De manera simultánea a la confirmación de la entrega física a través de los sensores receptores, el código del contrato inteligente autoejecuta la liberación de los activos financieros depositados bajo la modalidad de cuenta de garantía o escrow. Esta liquidación fiduciaria autónoma transfiere el pago directamente al proveedor por los bienes entregados, lo cual consolida una relación comercial de máxima transparencia y forja una cadena de suministro resiliente fundamentada en datos criptográficos irrefutables.




Figura 4. Arquitectura operativa del contrato inteligente para el reabastecimiento logístico autónomo

Nota. La secuencia ilustra la supresión de la intermediación manual mediante la convergencia de telemetría IoT y protocolos distribuidos. El nodo de decisión condicional subordina el aprovisionamiento al umbral predictivo del Punto de Reorden. La confirmación material de la carga desencadena la liquidación fiduciaria en el libro mayor inmutable, lo cual consolida la trazabilidad y mitiga el efecto látigo en la cadena de suministro. Elaboración propia.

3.2 Lote Económico Dinámico

La evolución del modelo de Cantidad Económica de Pedido (EOQ) hacia un esquema de Lote Económico Dinámico representa la transición de una gestión de inventarios estática a un sistema de optimización estocástica en tiempo real. A diferencia de la formulación clásica de Harris-Wilson, la cual asume una demanda determinista y costos de mantenimiento invariables, la propuesta adaptativa para Casserissima integra algoritmos de Machine Learning que recalibran la ecuación de pedido mediante la ingesta continua de flujos de datos externos. Este enfoque permite que el lote óptimo se ajuste automáticamente ante la volatilidad de la demanda y las restricciones operativas, lo cual asegura una respuesta ágil frente a la incertidumbre inherente al mercado de productos perecederos (Silver et al., 2016).

La arquitectura del algoritmo modifica los parámetros de la raíz cuadrada tradicional al ponderar dinámicamente tres variables críticas para el modelo de negocio pastelero: la estacionalidad de la demanda de corto plazo, el índice de inflación de los insumos y la variabilidad en la vida útil de los productos lácteos. El sistema procesa estas métricas para alterar el costo de mantenimiento del inventario y la magnitud de la orden de compra en función del riesgo de caducidad. Por consiguiente, el algoritmo reduce el tamaño del lote cuando detecta un incremento en la temperatura promedio que eleve los costos de refrigeración o cuando los indicadores predictivos sugieren una contracción en el consumo. Esta flexibilidad paramétrica garantiza la minimización del costo total de gestión y erradica el exceso de stock de baja rotación que compromete la liquidez de la pastelería.

FASE IV: OPTIMIZACIÓN Y MACHINE LEARNING

4.1 Punto de Reorden Evolutivo

La transición hacia una gestión de inventarios inteligente en la pastelería Casseríssima se fundamenta en la superación de las vulnerabilidades críticas identificadas en el diagnóstico operativo, donde la política empírica de reabastecimiento —anclada en un punto de reorden estático de 40 cartones de huevo— arroja una probabilidad de quiebre de stock del 32.10%. Esta fragilidad estructural emana de una inestabilidad logística severa, caracterizada por tiempos de entrega (Lead Time) que oscilan de forma errática entre 2 y 11 días. Ante este escenario, la presente fase implementa un modelo de Machine Learning basado en Bosques Aleatorios (Breiman, 2001), diseñado para ingerir datos exógenos no estructurados, como pronósticos climáticos y métricas de congestión vehicular en las rutas de suministro locales. A diferencia de los métodos deterministas, este algoritmo captura las relaciones no lineales entre las perturbaciones ambientales y la variabilidad del transporte, lo cual permite proyectar con precisión matemática los retrasos esperados en el suministro de insumos críticos.

La arquitectura propuesta recalcula de forma autónoma y dinámica el Punto de Reorden (ROP) al integrar la predicción del Lead Time en tiempo real con la volatilidad de la demanda diaria, la cual fluctúa significativamente entre 3 y 12 unidades. El sistema ajusta el umbral de inventario preventivo antes de que ocurra la ruptura física, lo cual blindará las líneas de producción de la pastelería de vitrina contra el "Efecto Látigo" provocado por órdenes manuales sobredimensionadas. Al desplazar el ROP con base en la inminencia de retrasos externos, el modelo minimiza tanto el riesgo de desabastecimiento como la acumulación de insumos perecederos. Este enfoque de optimización estocástica garantiza que el nivel de existencias responda a la realidad del entorno logístico, lo cual erradica la dependencia en la intuición humana y asegura la continuidad operativa frente a picos de demanda o crisis de transporte (Silver, Pyke & Thomas, 2016)

4.2 Almacenamiento Inteligente (Optimización de Layout)

La optimización de la cadena de suministro se complementa con una reestructuración espacial del almacén orientada a mitigar las mermas por caducidad y las ineficiencias en el flujo interno de materiales detectadas en la fase diagnóstica. La propuesta de diseño de planta adopta la Planeación Sistemática de Distribución (Muther, 1973) junto con heurísticas de ruteo para minimizar la distancia total recorrida en la manipulación de materias primas. El algoritmo de optimización evalúa la alta susceptibilidad a la degradación de los insumos de la pastelería y asigna ubicaciones estratégicas a los ingredientes de mayor peso y rotación, tales como harinas, lácteos y cartones de huevo. La disposición resultante sitúa estos elementos en zonas de alta proximidad a las áreas de preparación, lo cual reduce drásticamente los tiempos de traslado interno y mejora la ergonomía operativa (Tompkins, White, Bozer & Tanchoco, 2010).

Este almacenamiento inteligente implementa una zonificación dinámica que facilita la rotación estricta de existencias bajo el principio de primeros en expirar, primeros en salir. Al optimizar el layout, el sistema reduce los cuellos de botella que actualmente paralizan las líneas de horneado cuando la demanda acumulada perfora la barrera del inventario. La integración de esta lógica espacial con la infraestructura sensorial de oráculos IoT permite una visibilidad absoluta del stock físico. En consecuencia, la distribución algorítmica de la planta no solo optimiza el espacio cúbico del depósito, sino que actúa como un mecanismo de control preventivo contra el exceso de inventario de baja rotación. Esta sinergia entre el diseño de instalaciones y la analítica de datos transforma el almacén en un nodo resiliente que absorbe la varianza de la demanda y garantiza la integridad de los productos perecederos hasta su transformación final.

CONCLUSIÓN

El diagnóstico operativo y la posterior evaluación estocástica ejecutada sobre la cadena de suministro de la pastelería Casseríssima demuestran la inoperancia matemática de las políticas de reabastecimiento actuales. La simulación computacional de Monte Carlo cuantificó una probabilidad de quiebre de stock del 32.10% frente a la volatilidad real de la demanda y la latencia logística de los proveedores locales. Esta métrica irrefutable confirma que el modelo empírico de gestión somete a la organización a un nivel de riesgo financiero insostenible, propiciando ciclos destructivos de escasez de insumos críticos y mermas por caducidad. Este hallazgo evidencia la urgencia de abandonar la toma de decisiones basada en la intuición para transitar hacia un paradigma logístico rigurosamente analítico.

La arquitectura tecnológica propuesta resuelve esta deficiencia al delegar el control del inventario a un ecosistema autónomo y predictivo. La convergencia de algoritmos de Machine Learning y oráculos de telemetría IoT permite el cálculo de un punto de reorden evolutivo, anticipando las perturbaciones del entorno antes de que impacten la línea de horneado. Simultáneamente, la integración de contratos inteligentes en una red descentralizada garantiza una ejecución de compras transparente, lo cual elimina por completo la distorsión del efecto látigo hacia los distribuidores mayoristas. Finalmente, la sinergia de esta digitalización con la reestructuración algorítmica del almacén consolida una operación resiliente, capaz de salvaguardar la liquidez de la empresa y asegurar la calidad irrestricta de los productos ofertados al consumidor final.

REFERENCIAS BIBLIOGRAFICAS

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.
- Chase, R. B., & Jacobs, F. R. (2014). *Administración de operaciones: Producción y cadena de suministros* (13a ed.). McGraw-Hill.
- Christidis, K., & Devetsikiotis, M. (2016). Blockchains and smart contracts for the internet of things. *IEEE Access*, 4, 2292-2303.
- Kshetri, N. (2018). 1 Blockchain's roles in meeting key supply chain management objectives. *International Journal of Information Management*, 39, 80-89.
- Muther, R. (1973). *Systematic layout planning* (2nd ed.). Cahnerns Books.
- Mweshi, G. K. (2022). The Bullwhip Effect in Supply Chain Management: A Literature Review. *International Journal of Logistics and Supply Chain Management Perspectives*, 11
- Saberi, S., Kouhizadeh, M., Sarkis, J., & Shen, L. (2019). Blockchain technology and its relationships to sustainable supply chain management. *International Journal of Production Research*, 57(7), 2117-2135.
- Silver, E. A., Pyke, D. F., & Thomas, D. J. (2016). *Inventory and production management in supply chains* (4th ed.). CRC Press.
- Tompkins, J. A., White, J. A., Bozer, Y. A., & Tanchoco, J. M. A. (2010). *Facilities planning* (4th ed.). John Wiley & Sons.

ANEXOS

Código Fuente: Simulación Monte Carlo y Análisis de Sensibilidad

Descripción: El presente script, desarrollado en el lenguaje de programación Python, constituye el motor de simulación estocástica aplicado a la línea de perecederos (cartones de huevo). El algoritmo incorpora un ciclo de evaluación de sensibilidad que itera sobre diferentes umbrales del Punto de Reorden (ROP) para cuantificar la variación en la probabilidad de quiebre de stock frente a la latencia logística (Lead Time) y la fluctuación del consumo interno.

Python

```
import numpy as np

import pandas as pd

import matplotlib.pyplot as plt

#
=====
=====

# 1. PARÁMETROS BASE DEL MODELO ESTOCÁSTICO (Caso:
Casseríssima)

#
=====
=====

np.random.seed(42) # Semilla para reproducibilidad académica

ITERACIONES = 10000

# Rango de Puntos de Reorden (ROP) a evaluar para el Análisis de
Sensibilidad
```

```
# Se evaluarán escenarios desde 30 hasta 65 cartones con saltos de 5 unidades
```

```
escenarios_rop = range(30, 70, 5)
```

```
# Matriz para almacenar los resultados del análisis
```

```
resultados_sensibilidad = []
```

```
print("INICIANDO ANÁLISIS DE SENSIBILIDAD MONTE CARLO...")
```

```
print("-----")
```

```
print(f'{"Punto de Reorden (ROP)":<25} | {"Probabilidad de Quiebre (%)"}')
```

```
print("-----")
```

```
#
```

```
=====
```

```
# 2. MOTOR DE SIMULACIÓN Y ANÁLISIS DE SENSIBILIDAD
```

```
#
```

```
=====
```

```
# El bucle externo itera sobre las políticas de inventario posibles
```

```
for rop_evaluado in escenarios_rop:
```

```
    eventos_quiebre = 0
```

```
    # El bucle interno ejecuta los 10,000 escenarios logísticos para ese ROP
```

```
    for _ in range(ITERACIONES):
```

```
        # Variable estocástica 1: Lead Time (Distribución Triangular: 2, 5, 11 días)
```

```
        lead_time = int(np.random.triangular(left=2, mode=5, right=11))
```

```
        demanda_acumulada = 0
```

```
# Variable estocástica 2: Demanda Diaria (Distribución Triangular: 3, 6, 12 cartones)
```

```
for dia in range(lead_time):
```

```
    demanda_diaria = int(np.random.triangular(left=3, mode=6, right=12))
```

```
    demanda_acumulada += demanda_diaria
```

```
# Cuantificación del fallo logístico
```

```
if demanda_acumulada > rop_evaluado:
```

```
    eventos_quiebre += 1
```

```
# Cálculo estadístico para el escenario actual
```

```
probabilidad_falla = (eventos_quiebre / ITERACIONES) * 100
```

```
resultados_sensibilidad.append(probabilidad_falla)
```

```
# Impresión tabular de la sensibilidad
```

```
print(f"{rop_evaluado:<25} | {probabilidad_falla:>25.2f}%")
```

```
print("-----")
```

```
#
```

```
=====
=====
```

```
# 3. RENDERIZADO VISUAL DEL ANÁLISIS DE SENSIBILIDAD
```

```
#
```

```
=====
=====
```

```
plt.figure(figsize=(10, 6))
```

```
# Trazado de la curva de sensibilidad
```

```
plt.plot(escenarios_rop, resultados_sensibilidad, marker='o', color='#2C3E50',
```

```

        linewidth=2.5, markersize=8, label='Curva de Riesgo Logístico')

# Demarcación de la política empírica actual (Diagnóstico Fase I)

plt.axvline(x=40, color='#E74C3C', linestyle='--', linewidth=2,

            label='ROP Actual Casseríssima (40 uds)')

# Formateo académico

plt.title('Análisis de Sensibilidad: Probabilidad de Quiebre vs Punto de
Reorden',

          fontsize=14, fontweight='bold', pad=15)

plt.xlabel('Punto de Reorden Evaluado (Unidades de Inventario)', fontsize=12)

plt.ylabel('Probabilidad de Quiebre de Stock (%)', fontsize=12)

plt.grid(axis='both', linestyle='--', alpha=0.6)

plt.legend(fontsize=11)

plt.tight_layout()

# Despliegue de la gráfica

plt.show()

```